# درون شبکه، شبکه های اجتماعی

نویسندگان: آرجون روی (Arjun Roy) دکترای علوم کامپیوتر از دانشگاه کالیفرنیا سن دیگو، هونگی زنگ (Hongyi Zeng) دکترای مهندسی برق از دانشگاه استنفورد کالیفرنیا، جاسمیت باگا (Jasmeet Bagga) دانشجوی دکترای علوم کامپیوتر در دانشگاه کالیفرنیا سن دیگو، جورج پورتر(George Porter) استاد دانشگاه کالیفرنیا سن دیگو ، الکس سی. اسنورن (Alex C. Snoeren) رئیس دانشکده شبکه های کامپیوتری در دانشگاه کالیفرنیا

با همکاری: دپارتمان علوم کامپیوتر و مهندسی در دانشگاه کالیفرنیا، سن دیگو و شرکت فیسبوک

**چکیده**

ارائه‌دهندگان خدمات ابری بزرگ، سرمایه‌گذاری کرده‌اند در مراکز داده به طور فزاینده‌ای بزرگتر تا جای دهند زیرساخت محاسباتی مورد نیاز را برای پشتیبانی از خدماتشان. بر این اساس، محققان و کارشناسان صنعت به طور یکسان تمرکز کرده‌اند مقدار زیادی از تلاش را بر روی طراحی بافت‌های شبکه برای به طور کارآمد به هم متصل کردن و مدیریت کردن ترافیک درون این مراکز داده در شیوه‌های با عملکرد در عین حال کارآمد. متاسفانه، اپراتورهای مرکز داده به طور کلی بی‌میل هستند تا به اشتراک بگذارند نیازهای واقعی اپلیکیشن‌هایشان را، که این امر آن را چالش‌برانگیز می‌کند تا ارزیابی شود عملی بودن هر طراحی خاصی. علاوه بر این، اطلاعات محدود حجم کاری در مقیاس بزرگ در دسترس در ادبیات (علمی) تا حد زیادی، چه خوب و چه بد، تاکنون توسط یک اپراتور مرکز داده منفرد فراهم شده است که موارد استفاده‌اش ممکن است گسترده نباشد. در این کار، ما گزارش می‌کنیم در مورد ترافیک شبکه مشاهده شده در برخی از مراکز داده فیس‌بوک. در حالی که فیس‌بوک اجرا می‌کند تعدادی از خدمات سنتی مرکز داده مانند هدوپ، خدمات اصلی وب و زیرساخت کش پشتیبان آن نمایش می‌دهند تعدادی رفتار که در تضاد هستند با آن‌هایی که گزارش شده‌اند در ادبیات (علمی). ما گزارش می‌دهیم در مورد محلی بودن متضاد، پایداری، و قابلیت پیش‌بینی ترافیک شبکه در مراکز داده فیس‌بوک، و توضیح می‌دهیم در مورد پیامدهای آن‌ها برای معماری شبکه، مهندسی ترافیک، و طراحی سوئیچ.

# Inside the Social Network's (Datacenter) Network

Authors: Arjun Roy, PhD in Computer Science from University of California, San Diego, Hongyi Zeng, PhD in Electrical Engineering from Stanford University, California, Jasmeet Bagga, PhD student in Computer Science at University of California, San Diego, George Porter, Professor at University of California, San Diego, Alex C. Snoeren, Department Chair of Computer Networks at University of California

with collaboration of: Department of Computer Science and Engineering at University of California, San Diego, and Facebook company

**Abstract**

Large cloud service providers have invested in increasingly larger datacenters to house the computing infrastructure required to support their services. Accordingly, researchers and industry practitioners alike have focused a great deal of effort designing network fabrics to efficiently interconnect and manage the traffic within these datacenters in performant yet efficient fashions. Unfortunately, datacenter operators are generally reticent to share the actual requirements of their applications, making it challenging to evaluate the practicality of any particular design. Moreover, the limited large-scale workload information available in the literature has, for better or worse, heretofore largely been provided by a single datacenter operator whose use cases may not be widespread. In this work, we report upon the network traffic observed in some of Facebook's datacenters. While Facebook operates a number of traditional datacenter services like Hadoop, its core Web service and supporting cache infrastructure exhibit a number of behaviors that contrast with those reported in the literature. We report on the contrasting locality, stability, and predictability of network traffic in Facebook's datacenters, and comment on their implications for network architecture, traffic engineering, and switch design.

| یافته | داده‌های منتشر شده قبلی | پیامدهای بالقوه |
|---|---|---|
| ترافیک نه محلی به رک است و نه همه‌به‌همه؛ استفاده (از پهنای باند) پایین (بخش ۴) | [12،17] ترافیک در حد محلی رک است ۸۰٪-۵۰ | [4،21 ،36] بافت‌های مراکز داده |
| تقاضا گسترده، یکنواخت و پایدار است، با ترافیک‌های سنگینِ ناگهانی و داخلی که به سرعت تغییر می‌کنند (بخش ۵) | [12،14 ،13] تقاضا اغلب متمرکز و ناگهانی است | [5،39 ،25 ،14] مهندسی ترافیک |
| بسته‌های کوچک (خارج از هدوپ)، ورودی‌های پیوسته؛ جریان‌های همزمان متعدد (بخش ۶) | ؛ رفتار روشن/خاموش ACK/MTU اندازه بسته دوحالتیِ [8] [۱۲]؛ کمتر از ۵ جریان بزرگ همزمان | [34،1] SDN کنترل‌کننده‌های ؛ [،22 ،28 ،32 ،7،39 ،30 ،20] سوئیچینگ مداری/ترکیبی |

جدول ۱: هر یک از یافته‌های اصلی ما با توصیفات منتشر شده قبلی در مورد ترافیک مرکز داده متفاوت است. بسیاری از سیستم‌ها یک یا چند مورد از ویژگی‌های منتشر شده قبلی را به عنوان فرضیات طراحی در نظر می‌گیرند.

## ۱ .مقدمه

مراکز داده در حال ایجاد انقلابی در نحوه طراحی شبکه‌ها هستند. این امر تا حد زیادی به دلیل محدودیت‌های مهندسی بسیار بزرگی است که هنگام اتصال گره‌های مستقل و بسیار به هم وابسته در فضایی نسبتاً کوچک ایجاد می‌شود، در مقابلِ گره‌های پایانی کاملاً ناهمگنی که به صورت پراکنده در سطح جهان قرار دارند.

در حالی که بسیاری از جنبه‌های طراحی شبکه و پروتکل به این ویژگی‌های فیزیکی وابسته است، برخی دیگر به درک محکمی از تقاضایی که بر روی شبکه تحمیل خواهد شد، نیاز دارند. متأسفانه، ما با یک معضل بزرگ در مورد موضوع اول (یعنی این‌که مراکز داده ابری مدرن ده‌ها هزار سرور را با استفاده از ترکیبی از اتصالات ۱۰-گیگابیت اترنت و مقادیر فزاینده‌ای از اتصالات فیبر پرسرعت به هم متصل می‌کنند) روبرو هستیم، اما موضوع دوم به طور عمومی فاش نمی‌شود.

از این رو، بسیاری از پیشنهادات اخیر بر پایه فرضیات تأیید نشده‌ای در مورد حجم کاری مراکز داده بوده‌اند. در برخی موارد، این فرضیات از داده‌های ردیابی (traces) حجم کاری یک اپراتور بزرگ مرکز داده گرفته شده است. این ردیابی‌ها تحت سلطه ترافیکی هستند که به عنوان بخشی از یک سرویس اصلی جستجوی وب ایجاد می‌شود، که ممکن است با تقاضاهای سایر سرویس‌های ابری بزرگ تفاوت چشمگیری داشته باشد.

در این مقاله، ما نمونه‌هایی از حجم کاری را که در برخی از مراکز داده فیس‌بوک مشاهده شده است، بررسی می‌کنیم. ما دریافتیم که مطالعات ترافیکی در ادبیات علمی کاملاً نماینده تقاضاهای فیس‌بوک نیستند، که این امر کاربردپذیری برخی از پیشنهادات بر اساس این فرضیات را در مورد رفتار ترافیک مرکز داده زیر سوال می‌برد. این وضعیت به ویژه در مورد بافت‌های شبکه جدید، پروتکل‌های مهندسی ترافیک، و طراحی سوئیچ‌ها حادتر است.

به عنوان مثال، تلاش زیادی برای شناسایی توپولوژی‌های کارآمد برای اتصالات داخلی مراکز داده صورت گرفته است [۴, ۱۹, ۲۱, ۳۶]. بهترین انتخاب (از نظر تعادل هزینه/منفعت) به الگوی ارتباطی بین گره‌های پایانی [۳۳] بستگی دارد. به دلیل کمبود داده‌های بتنی، محققان اغلب برای بدترین حالت طراحی می‌کنند، یعنی یک ماتریس ترافیک همه‌به‌همه که در آن هر سرور با هر سرور دیگر با فرکانس و شدت یکسان ارتباط برقرار می‌کند [۴]. چنین فرضیاتی منجر به هدف ارائه پهنای باند برش‌دوم (bisection bandwidth)حداکثری [۴, ۲۳, ۳۶] می‌شود، که ممکن است در صورت نمایش تقاضای واقعی، بیش از حد نیاز باشد] ۱۷.[

در عمل، مراکز داده تولیدی تمایل به اعمال درجه مشخصی از فروش بیش از حد] (oversubscription) ۲۱, ۱۲ [دارند، با این فرض که پهنای باند گره پایانی از تقاضاهای ترافیکی واقعی فراتر رود یا تقاضا برای اتصال در مقیاس بزرگ، در واقعیت به نیاز به اتصالی در مقیاس کوچک تبدیل می‌شود. از آنجا که درجه بیش‌فروشی فیزیکی ( Physical oversubscription) بین دپارتمان‌های مختلف به طور نامتناسبی متفاوت است، در مورد اینکه آیا این بیش‌فروشی‌ها به طور کامل قابل اعتماد هستند، اجماع کمی وجود دارد. برای کاهش "نقاط داغ" بالقوه ناشی از بیش‌فروشی، محققان پیشنهاد کرده‌اند که اتصال‌پذیری بین بخش‌هایی از مراکز داده را بهبود ببخشند [۵, ۲۵, ۴۰]. سودمندی این رویکردها به شدت به حضور و پویایی این نقاط داغ بستگی دارد.

به ویژه، محققان پیشنهاداتی را برای پارچه‌های شبکه غیریکنواخت ارائه کرده‌اند که می‌توانند اتصالات کیفی متفاوتی را به بخش‌های خاصی از مراکز داده بزرگ فراهم کنند، معمولاً از طریق طرح‌های ترکیبی، که به صورت نوری [۳۰, ۳۹] یا بی‌سیم [۲۵, ۴۰] اجرا می‌شوند. اگر تقاضا قابل پیش‌بینی یا در فواصل زمانی معقول پایدار باشد، ممکن است بتوان یک مدار شبیه به اتصال را بین بخش‌های مراکز داده ایجاد کرد. در غیر این صورت، کنترل‌های شبکه باید مسیرهای جایگزین را به صورت هوشمندانه پیدا کنند [۱۴]. با این وجود، همه این تکنیک‌ها به مقداری قابلیت پیش‌بینی برای ترافیک نیاز دارند، چیزی که در دوره‌های غیربحرانی قابل مشاهده نیست [۱۴, ۲۰, ۲۵, ۳۰, ۳۹].

در نهایت، اغلب مشاهده شده که ترافیک مرکز داده افق‌های جدیدی را برای افزایش کارایی شبکه باز می‌کند. به ویژه، برخی تغییرات اصلاح‌شده پیشنهادی در مورد حجم کاری مراکز داده، از جمله بافرینگ با شدت کمتر، کنترل پورت، یا ترکیب [۴] در لایه‌های مختلف سوئیچینگ، پیشنهادهای قبلی در مورد بسته‌های قراردادی را با سوئیچ‌ها یا طراحی‌های ترکیبی جایگزین کرده‌اند که از مزایای محلی‌گرایی (locality)، قابلیت پیش‌بینی و پایداری ترافیک برای مسیریابی مستقیم اتصالات گره‌های پایانی استفاده می‌کنند [۳۰]. علاوه بر این، راه حل‌های مبتنی بر سخت‌افزار افراطی برای مسیریابی مستقیم اتصالات گره‌های پایانی [۲۱, ۲۳]، که در آن و/یا در صورت وجود، رویکردها مزایای اقتصادی قابل توجهی را بر روی بارهای کاری ارائه شده به دست می‌آورند [۳۳].

در حالی که تعداد زیادی مطالعه دانشگاهی و خصوصی [۱۴, ۱۷, ۲۱, ۲۳, ۲۶] وجود دارد، بسیاری از آنها کاملاً بر اساس ارزیابی حجم کاری مراکز داده بزرگ (یا ترافیک مراکز داده ابری) [۱۱, ۱۲, ۱۷, ۲۱, ۲۳, ۲۶] هستند که برخی مطالعات، مانند مایکروسافت، آنها را به عنوان ماشین‌های مجازی [۱۴] در نظر می‌گیرند، که رفتار برنامه بسیار متفاوتی را نشان می‌دهند. ما یک مجموعه متمایز از تمایزات را مشاهده می‌کنیم که ممکن است منجر به نتیجه‌گیری‌های کیفی متفاوتی شود؛ بنابراین، ما این تفاوت‌ها را توصیف می‌کنیم و پیامدهای آنها را توضیح می‌دهیم.

مطالعه ما اولین گزارش در مورد ترافیک تولیدی در یک شبکه مرکز داده است که هزاران گره را با استفاده از سوئیچینگ ۱۰-گیگابیت در سراسر سیستم‌های نظارت گسترده فیس‌بوک به هم متصل می‌کند و بسته‌های ترافیکی را برای هر گره بررسی می‌کنیم تا الگوهای ترافیکی که در شبکه فیس‌بوک به وجود می‌آیند را بررسی کنیم. ما دریافتیم که استقرار هدوپ فیس‌بوک به خوبی با ترافیک در ادبیات گزارش شده مطابقت دارد، اما بخش قابل توجهی از معماری خدمات فیس‌بوک [۱۰, ۱۵]، که به صورت دراماتیک از مطالعات زیرساختی MapReduce قبلی متفاوت است، دارای پیامدهای معماری متفاوتی است. یافته‌های ما از مطالعه دارای پیامدهای معماری قابل توجهی به شرح زیر است:

- **ترافیک نه بر اساس رک و نه بر اساس همه به همه است :**محلی بودن به عملکرد از گره‌های پایانی تا سوئیچ‌ها بستگی دارد. روزهای پایدار ممکن است از مزایای بیش‌فروشی و پهنای باند کمتر در میان رک‌ها بهره‌مند شوند.
- **جریان‌های ترافیکی برای مدت طولانی زنده هستند، اما بسیار سنگین نیستند :**توازن بار مؤثر ترافیک در سراسر میزبان‌ها مهم است، به طوری که تقاضاهای ترافیک در طول دوره‌های چند ثانیه‌ای کاملاً پایدار می‌مانند، اما ترافیک سنگین جریان‌های ترافیکی به طور قابل توجهی بزرگتر از میانگین جریان‌ها نیستند و وزن بسته به سرعت تغییر می‌کند. جریان‌های ترافیکی سنگین‌تر اغلب به طور ناگهانی به وجود می‌آیند، نه در طول دوره‌های طولانی‌تر، و به طور بالقوه رویکردهای گیج‌کننده مهندسی ترافیک را به وجود می‌آورند.
- **بسته‌ها کوچک هستند :**(میانگین برای ترافیک غیر هدوپ کمتر از ۲۰۰ بایت است) و رفتار ورود/خروج ناگهانی از خود نشان نمی‌دهند. سرورها با ۱۰۰ها میزبان ارتباط برقرار می‌کنند و رک‌ها به طور همزمان (یعنی در یک بازه زمانی ۵ میلی‌ثانیه‌ای) ارتباط برقرار می‌کنند، اما بیشتر ترافیک به یک (یا چند) میزبان مقصد محدود می‌شود. در حالی که ما این حجم کاری‌ها را به عنوان نماینده مطلق خدمات فیس‌بوک ارائه نمی‌کنیم - ممکن است با تغییر خدمات فیس‌بوک تغییر کنند - آنها کاربردپذیری حجم کاری مراکز داده در ادبیات را نشان می‌دهند. یافته‌های ما در جدول ۱ نشان می‌دهد که چگونه نتایج ما در مقایسه با ادبیات و همچنین مثال‌های کلاسی که این فرضیات را در خود جای داده‌اند، متفاوت است.

بقیه این مقاله به شرح زیر سازماندهی شده است. بخش ۲ با مروری بر مطالعات قبلی در مورد ترافیک مرکز داده آغاز می‌شود. بخش ۳ یک توصیف سطح بالا از سازمان فیس‌بوک، خدمات آنها، و روش‌های پشتیبانی جمع‌آوری داده‌ها ارائه می‌دهد. ما سپس جنبه‌های ترافیک درون یک مرکز داده فیس‌بوک را تجزیه و تحلیل می‌کنیم (بخش ۴)، مهندسی ترافیک (بخش ۵)، و طراحی سوئیچ (بخش ۶)، قبل از نتیجه‌گیری در بخش ۷.

## ۲ .کارهای مرتبط

مطالعات اولیه در مورد بارهای کاری مراکز داده از طریق شبیه‌سازی [۶] یا در محیط‌های آزمایشی [۱۸] انجام شد. با این حال، پس از آن، تعدادی مطالعه در مورد ترافیک مراکز داده تولیدی، عمدتاً در مراکز داده مایکروسافت، صورت گرفته است. مشخص کردن اینکه چند مرکز داده متمایز مایکروسافت در ادبیات علمی گزارش شده‌اند یا آن مجموعه چقدر می‌تواند نماینده باشد، دشوار است. کندولا و همکاران مشاهده می‌کنند که نتایج آنها "به سایر مراکز داده استخراج که از نوعی محاسبات جریان کاری به سبک مپ‌ریدیوس بر روی یک انبار بلوک توزیع‌شده استفاده می‌کنند، تعمیم می‌یابد"، اما هشدار می‌دهند که "مراکز داده وب یا ابری که عمدتاً با تولید پاسخ برای درخواست‌های وب (مثلاً ایمیل، پیام‌رسان) سروکار دارند، احتمالاً ویژگی‌های متفاوتی دارند" [۲۶]. طبق این دسته‌بندی، مراکز داده فیس‌بوک به وضوح در دسته دوم قرار می‌گیرند. جلپرتی و همکاران [۲۴] تأخیر را برای سرویس‌های بینگ مایکروسافت بررسی می‌کنند؛ ما اشاره می‌کنیم که هر دو از نظر مفهوم شبیه به خدمات فیس‌بوک هستند، اما بار کاری ما (استفاده نسبتاً کم همراه با الگوی ترافیک سبک پراکنده-تجمع) و تفاوت‌ها (بار به نظر می‌رسد به طور یکنواخت‌تر در مراکز داده فیس‌بوک توزیع شده است) احتمالاً ویژگی‌های متفاوتی دارند.[26]

سه موضوع اصلی در مطالعات قبلی غالب هستند و در جدول ۱ خلاصه شده‌اند. اولاً، ترافیک به شدت محلی به رک (rack local) یافت شده است، که احتمالاً پیامد الگوهای برنامه‌ای مشاهده شده است؛ بنسون و همکاران اشاره می‌کنند که برای مراکز داده ابری، "اکثر ترافیک تولید شده توسط سرورها (٪۸۰) در داخل رک باقی می‌ماند" [۱۲]. مطالعات کندولا و همکاران [۲۶]، دلیمیترو و همکاران [۱۷] و علیزاده و همکاران [۸] الگوهای ترافیکی مشابهی را با غلظت بالا در رک مشاهده می‌کنند.

دوماً، ترافیک اغلب به عنوان ناگهانی (bursty) و ناپایدار در طیف وسیعی از مقیاس‌های زمانی گزارش شده است—یک مشاهده مهم، زیرا تکنیک‌های مهندسی ترافیک اغلب به جریان‌های نسبتاً طولانی و قابل پیش‌بینی وابسته هستند. رائو و همکاران مشاهده می‌کنند که بسته‌ها به یک مقصد مشخص اغلب به صورت "قطاری" می‌رسند [۲۷]؛ در حالی که بنسون و همکاران یک الگوی قوی "روشن/خاموش" پیدا می‌کنند که در آن فاصله زمانی بین بسته‌ها از توزیع لگ‌نرمال پیروی می‌کند [۱۳]. تغییر مقیاس زمانی مشاهده می‌تواند وضعیت پیش‌بینی را تغییر دهد؛ دلیمیترو و همکاران [۱۷] اشاره می‌کنند که در حالی که محلی‌گرایی ترافیک به صورت روزانه متفاوت است، در مقیاس چند ماه ثابت می‌ماند.

برعکس، بنسون و همکاران [۱۴] ادعا می‌کنند که در حالی که ترافیک در مقیاس‌های زمانی ۱۵۰ ثانیه و بیشتر غیرقابل پیش‌بینی است، می‌تواند در مقیاس زمانی چند ثانیه نسبتاً پایدار باشد، و مکانیسم‌های مهندسی ترافیک را که ممکن است برای چنین ترافیکی کار کنند، مورد بحث قرار می‌دهند.

در نهایت، مطالعات قبلی به طور مداوم اندازه بسته "دووجهی" (bimodal)را گزارش کرده‌اند [۱۲]، که در آن بسته‌ها یا به MTU نزدیک می‌شوند یا کاملاً کوچک باقی می‌مانند، مانند یک سگمنت TCP ACK. ما دریافتیم که ترافیک فیس‌بوک بسیار متفاوت است، با یک اندازه میانه بسته که به طور مداوم کوچک است، با وجود سرعت لینک ۱۰-گیگابیت بر ثانیه. محققان همچنین گزارش کرده‌اند که میزبان‌های نهایی (end hosts)معمولاً تنها با چند (مثلاً کمتر از ۵[8] ) مقصد در یک زمان ارتباط برقرار می‌کنند. برای برخی از سرویس‌های فیس‌بوک، یک میزبان به تنهایی ده‌ها یا تعداد بیشتری از اتصالات همزمان را برقرار می‌کند.

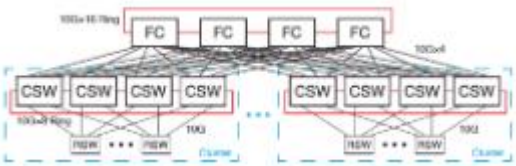
## ۳. یک مرکز داده فیس‌بوک

برای ایجاد زمینه لازم جهت تفسیر یافته‌های ما، این بخش یک نمای کلی کوتاه از فیس‌بوک ارائه می‌دهد.

**داده** نامیده می‌شود) است که هر مرکز داده حاوی چندین کلاستر است. یک **کلاستر** یک واحد استقرار در مراکز داده فیس‌بوک محسوب می‌شود. هر کلاستر از یک توپولوژی سه‌لایه متداول که در شکل ۱ نشان داده شده است، استفاده می‌کند که از یک مقاله کوتاه [۱۹] بازتولید شده است.

ماشین‌ها در قفسه‌ها (رک‌ها) سازماندهی شده و به یک سوئیچ بالای قفسه (RSW)با لینک‌های ۱۰-گیگابیت اترنت متصل می‌شوند. تعداد ماشین‌ها در هر قفسه از کلاستری به کلاستر دیگر متفاوت است. هر RSWنیز به نوبه خود با لینک‌های ۱۰-گیگابیتی به چهار سوئیچ

### ۳.۱ توپولوژی مرکز داده



شکل ۱: طراحی ۴-پستی کلاستر فیس‌بوک [۱۹]

توپولوژی شبکه مرکز داده فیس‌بوک، و همچنین توضیحی از سرویس‌های کاربردی که پشتیبانی می‌کند؛ جزئیات بیشتر در جای دیگر [۲، ۹، ۱۰، ۱۵، ۱۹] موجود است. سپس ما دو سیستم جمع‌آوری متمایز را که برای جمع‌آوری ردیابی‌های شبکه تحلیل‌شده در بقیه مقاله استفاده شده‌اند، توصیف می‌کنیم.

### ۳.۱ توپولوژی مرکز داده

شبکه فیس‌بوک از چندین سایت مرکز داده (که از این پس سایت نامیده می‌شود) و یک ستون فقرات برای اتصال این سایت‌ها تشکیل شده است. هر سایت شامل یک یا چند ساختمان مرکز داده (که از این پس مرکز داده نامیده می‌شود) است که هر مرکز داده حاوی چندین کلاستر است. یک کلاستر یک واحد استقرار در مراکز داده فیس‌بوک محسوب می‌شود. هر کلاستر از یک توپولوژی سه‌لایه متداول که در شکل ۱ نشان داده شده است، استفاده می‌کند که از یک مقاله کوتاه [۱۹] بازتولید شده است.

ماشین‌ها در قفسه‌ها (رک‌ها) سازماندهی شده و به یک سوئیچ بالای قفسه (RSW)با لینک‌های ۱۰-گیگابیت اترنت متصل می‌شوند. تعداد ماشین‌ها در هر قفسه از کلاستری به کلاستر دیگر متفاوت است. هر RSWنیز به نوبه خود با لینک‌های ۱۰-گیگابیتی به چهار سوئیچ تجمیع‌کننده که سوئیچ‌های کلاستر (CSW) نامیده می‌شوند، متصل می‌شود. گفته می‌شود که تمام قفسه‌هایی که توسط یک کلاستر CSW سرویس‌دهی می‌شوند، در یک کلاستر خاص قرار دارند. کلاسترها ممکن است از نظر ماشین‌آلات همگن باشند—برای مثال، کلاسترهای کش— یا ناهمگن، برای مثال، کلاسترهای فرانت‌اند که ترکیبی از سرورهای وب، توزیع‌کننده‌های بار و سرورهای کش را در بر می‌گیرند.CSW ها به لایه دیگری از سوئیچ‌های تجمیع‌کننده به نام Fat Cats (FC)متصل هستند. همانطور که بعداً در این مقاله دیده خواهد شد، این طراحی مستقیماً از نیاز به پشتیبانی مقدار زیادی از ترافیک درون کلاستری پیروی می‌کند. در نهایت، CSWها همچنین به سوئیچ‌های تجمیع برای ترافیک درون-سایتی (اما درون-مرکز داده‌ای) و روترهای مرکز داده برای ترافیک بین-سایتی متصل هستند.

بیشتر مراکز داده فعلی فیس‌بوک از این طرح ۴-پستی بسته استفاده می‌کنند. با این حال، کار در حال انجام برای مهاجرت مراکز داده فیس‌بوک به یک معماری نسل بعدی به نام **بافت (Fabric)** است [۹]. تحلیل‌های این مقاله بر اساس داده‌های جمع‌آوری‌شده از ماشین‌ها در کلاسترهای سنتی ۴-پستی و کلاسترهای جدیدتر بافت (برای مثال، جدول ۳) استوار است و میزبان‌ها را در سراسر فیس‌بوک پوشش می‌دهد.

یکی از جنبه‌های متمایز مراکز داده فیس‌بوک این است که هر ماشین معمولاً نقش دقیقاً یکسانی دارد: سرورهای وب (Web) ترافیک وب را سرویس می‌دهند؛ سرورهای (DB) **MySQL**داده‌های کاربران را ذخیره می‌کنند؛ نتایج کوئری به طور موقت در سرورهای کش (Cache) ذخیره

می‌شوند—شامل **لیدرها**، که هماهنگی کش را مدیریت می‌کنند، و **فالورها**، که اکثر درخواست‌های خواندن را سرویس می‌دهند [۱۵]؛ سرورهای **Hadoop**تحلیل آفلاین و داده‌کاوی را انجام می‌دهند؛ **فیدهای چندگانه (Multifeed (MF))** فیدهای خبری را گردآوری می‌کنند [۳۱]. در حالی که نقش‌های دیگری نیز وجود دارند، این نقش‌ها نماینده اکثریت هستند و تمرکز مطالعه ما خواهند بود. علاوه بر این، تعداد نسبتاً کمی از ماشین‌ها نقش ثابتی ندارند و به صورت پویا برای اهداف دیگر به کار گرفته می‌شوند. مراکز داده فیس‌بوک معمولاً ماشین‌های مجازی را در خود جای نمی‌دهند: هر سرویس بر روی یک سرور فیزیکی اجرا می‌شود. علاوه بر این—و در تضاد با مراکز داده مورد مطالعه قبلی [۱۲]—برای تسهیل در تأمین و مدیریت، قفسه‌ها معمولاً فقط شامل سرورهایی با همان نقش هستند.




شکل ۲: نحوه سرویس‌دهی یک درخواست HTTP

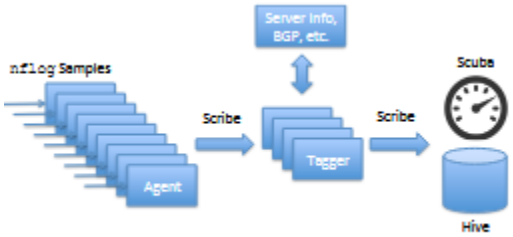



Figure 3: Fbflow architecture

شکل ۳: معماری Fbflow

| Type | Web | Cache | MF | SLB | Hadoop | Rest |
|---|---|---|---|---|---|---|
| Web | - | 63.1 | 15.2 | 5.6 | - | 16.1 |
| Cache-l | - | 86.6 | 5.9 | - | - | 7.5 |
| Cache-f | 88.7 | 5.8 | - | - | - | 5.5 |
| Hadoop | - | - | - | - | 99.8 | 0.2 |

جدول ۲: تفکیک درصد ترافیک خروجی برای چهار نوع میزبان مختلف

### ۳.۲ خدمات تشکیل‌دهنده

سازماندهی ماشین‌ها در یک کلاستر—و حتی یک مرکز داده—ارتباط نزدیکی با الگوهای ارتباطی بین سرویس‌هایی دارد که از آن‌ها پشتیبانی می‌کنند. ما با توصیف کوتاهی از نحوه سرویس‌دهی یک درخواست HTTPبه آدرس http://facebook.com که در شکل ۲ نشان داده شده است، سرویس‌های اصلی را معرفی می‌کنیم.

هنگامی که یک درخواست HTTP به یک مرکز داده فیس‌بوک می‌رسد، به یک **توزیع‌کننده بار نرم‌افزاری (SLB)** در لایه چهارم وارد می‌شود [۳۷]. سپس درخواست به یکی از سرورهای وب تغییر مسیر داده می‌شود. سرورهای وب تا حد زیادی **بی‌حالت (stateless)** هستند و هیچ داده کاربری را در خود نگه نمی‌دارند. آن‌ها داده‌ها را از **سطح کش (cache tier)** [15] بازیابی می‌کنند. در صورت عدم وجود داده در کش (cache miss)، سرور کش سپس داده‌ها را از **سطح پایگاه داده (database tier)** بازیابی خواهد کرد. در عین حال، سرور وب ممکن است با یک یا چند ماشین **بکند** ارتباط برقرار کند تا اشیایی مانند داستان‌های خبری و تبلیغات را بازیابی کند. جدول ۲ شدت ترافیک نسبی بین سرویس‌های مختلف را با دسته‌بندی ترافیک خروجی از چهار سرور مختلف—یک سرور وب، کش **لیدر** (cache-l)، کش **فالور** (cache-f)، و مبتنی بر **هدوپ**—بر اساس نقش میزبان مقصد، مشخص می‌کند. (داده‌ها از ردیابی‌های سرآیند بسته که در بخش ۳.۳.۲ توضیح داده شده، استخراج شده است).

برخلاف بیشتر سطوح خدماتی، گره‌های هدوپ در سرویس‌دهی به درخواست‌های کاربران نهایی نقشی ندارند. در عوض، کلاسترهای هدوپ **تحلیل‌های آفلاین** مانند داده‌کاوی را انجام می‌دهند **HDFS** و **Hadoop MapReduce**برنامه‌های اصلی هستند که روی این سرورها اجرا می‌شوند.

### ۳.۳ جمع‌آوری داده‌ها

با توجه به مقیاس مراکز داده فیس‌بوک، جمع‌آوری کامل **بسته‌های ترافیک شبکه (dumps)** غیرعملی است. در عوض، ما دو منبع متمایز از داده را در نظر می‌گیریم. اولی، **Fbflow**، به طور مداوم از سرآیندهای بسته در کل شبکه جهانی فیس‌بوک نمونه‌برداری می‌کند. دومی، **آینه‌سازی پورت(port mirroring)** ، در هر زمان بر روی یک ماشین (یا قفسه) واحد تمرکز می‌کند، که به ما امکان می‌دهد ردیابی‌های کامل سرآیند بسته را برای مدت کوتاهی در مکان‌های خاصی در یک مرکز داده واحد جمع‌آوری کنیم.

#### Fbflow۳.۳.۱

**Fbflow**یک سیستم نظارتی تولیدی است که از سرآیندهای بسته (packet headers)در کل ناوگان ماشین‌های فیس‌بوک نمونه‌برداری می‌کند. معماری آن، که از دو نوع مؤلفه اصلی—**نمایندگان (agents)**و **برچسب‌زنندگان—(taggers)** تشکیل شده است، در

شکل ۳ نشان داده شده است Fbflow .از طریق وارد کردن یک هدف Netfilter **nflog**به قوانین iptables هر ماشین، از بسته‌ها نمونه‌برداری می‌کند. مجموعه‌داده‌هایی که ما در این مقاله در نظر می‌گیریم با نرخ نمونه‌برداری ۱:۳۰،۰۰۰ جمع‌آوری شده‌اند. یک فرایند نماینده در سطح کاربر (user-level Fbflow) روی هر ماشین به سوکت nflog گوش می‌دهد و سرآیندها را تجزیه می‌کند و اطلاعاتی مانند آدرس‌های IP مبدأ و مقصد، شماره پورت‌ها و پروتکل را استخراج می‌کند. این سرآیندهای تجزیه‌شده—که در تمام ماشین‌های مراکز داده فیس‌بوک جمع‌آوری شده‌اند—به همراه ابرداده‌هایی مانند نام ماشین و زمان ثبت، به تعداد کمی از برچسب‌زنندگان با استفاده از **Scribe [2]**، یک سیستم تجمیع‌کننده لاگ، منتقل می‌شوند.

برچسب‌زنندگان، که بر روی زیرمجموعه‌ای از ماشین‌ها اجرا می‌شوند، بخشی از جریان سرآیند بسته را از Scribe می‌خوانند و آن را با اطلاعات اضافی مانند قفسه و کلاستری که ماشین جمع‌آوری‌کننده ردیابی در آن قرار داشته، شماره سیستم خودمختار آن و غیره، با جست‌وجو در منابع داده دیگر، بیشتر حاشیه‌نویسی می‌کنند. سپس برچسب‌زنندگان هر سرآیند بسته حاشیه‌نویسی‌شده را به یک شیء JSON تبدیل کرده و آن را به **Scuba [3]**، یک سیستم تحلیل داده در زمان واقعی، تغذیه می‌کنند. نمونه‌ها به طور همزمان در جداول **Hive [38]**برای تحلیل بلندمدت ذخیره می‌شوند.

### ۳.۳.۲ آینه‌سازی پورت

در حالی که Fbflow ابزاری قدرتمند برای نظارت و مدیریت شبکه است، جمع‌آوری مبتنی بر نمونه‌برداری آن مانع از انجام برخی از انواع تحلیل داده می‌شود. به طور خاص، در استفاده تولیدی، این ابزار آمار را در سطح دقت در هر دقیقه تجمیع می‌کند. برای جمع‌آوری داده‌های با دقت بالا، ما تعدادی ماشین جمع‌آوری ردیابی با هدف خاص را در داخل مرکز داده مستقر می‌کنیم که ردیابی‌های سرآیند بسته را در فواصل کوتاه جمع‌آوری می‌کنند.

ما میزبان‌های نظارتی را در پنج قفسه مختلف در شبکه مرکز داده فیس‌بوک مستقر می‌کنیم و آن‌ها را در کلاسترهایی قرار می‌دهیم که خدمات متمایزی را میزبانی می‌کنند. به طور خاص، ما یک قفسه از سرورهای وب، یک گره هدوپ، کش فالورها و لیدرها، و یک گره مالتی‌فید را نظارت می‌کنیم. به جز در یک مورد (وب)، ما ردیابی‌ها را با روشن کردن **آینه‌سازی پورت** بر روی ) **RSW**سوئیچ بالای قفسه **(**و آینه‌سازی ترافیک کامل و دوطرفه برای یک سرور واحد به سمت سرور جمع‌آوری خود، جمع‌آوری می‌کنیم. برای میزبان‌هایی که ما نظارت می‌کنیم، RSW قادر است پورت‌های انتخاب‌شده را بدون از دست دادن داده آینه‌سازی کند. در مورد سرورهای وب، میزان استفاده آنقدر کم است که ما قادر به آینه‌سازی ترافیک از یک قفسه سرورها به میزبان جمع‌آوری خود هستیم. ما در این مطالعه سرورهای پایگاه داده را که شامل داده‌های کاربر هستند، اندازه‌گیری نکردیم.

ضبط ردیابی‌های بسته با استفاده از یک سرور تجاری کاملاً بی‌اهمیت نیست، زیرا **tcpdump**قادر به مدیریت بیش از حدود ۱.۵ گیگابیت بر ثانیه از ترافیک در پیکربندی ما نیست. برای پشتیبانی از ردیابی‌ها با نرخ خط، ما از یک ماژول هسته سفارشی استفاده می‌کنیم که به طور موثری تمام RAM آزاد روی سرور را قفل کرده و از آن برای بافر کردن بسته‌های ورودی استفاده می‌کند. ماژول هسته ما بلافاصله پس از اینکه درایور اترنت بسته‌ها را به هسته تحویل می‌دهد، آن‌ها را استخراج می‌کند تا از هرگونه تأخیر یا سربار اضافی جلوگیری کند. هنگامی که جمع‌آوری داده‌ها کامل می‌شود، داده‌ها برای تحلیل به یک فضای ذخیره‌سازی از راه دور منتقل می‌شوند. محدودیت‌های حافظه در سرورهای جمع‌آوری ما، ردیابی‌هایی را که به این شیوه جمع‌آوری می‌کنیم، به چند دقیقه محدود می‌کند.

## ۴ .تأمین منابع

طراحی مناسب، مقیاس و حتی تکنولوژی اتصال داخلی یک مرکز داده به شدت به تقاضای ترافیکی سرویس‌هایی که میزبانی می‌کند بستگی دارد. در این بخش، ما شدت، محلی‌گرایی و پایداری ترافیک را در سه نوع کلاستر مختلف درون مراکز داده فیس‌بوک کمی‌سازی می‌کنیم؛ به ویژه، ما کلاسترهای پشتیبانی‌کننده هدوپ، ماشین‌های فرانت‌اند سرویس‌دهنده درخواست‌های وب، و کش را بررسی می‌کنیم.

مطالعه ما نشان می‌دهد که در حالی که استقرار هدوپ فیس‌بوک رفتاری را نشان می‌دهد که تا حد زیادی با ادبیات علمی سازگار است، همین امر را نمی‌توان در مورد کلاسترهای میزبان سایر خدمات فیس‌بوک گفت. به طور خاص، بیشتر ترافیک **محلی به رک نیست**، اما الگوهای محلی‌گرایی در فواصل زمانی طولانی (چند روزه) و کوتاه (دو دقیقه‌ای) پایدار باقی می‌مانند. ما ترافیک پایدار را به عنوان نزدیک به ثابت بودن (انحراف کم از یک مقدار پایه) در یک بازه زمانی، و تغییر آهسته در طول فواصل زمانی تعریف می‌کنیم. توجه داشته باشید که این تعریف به طول بازه زمانی مورد بررسی وابسته است؛ بر این اساس، ما چندین مقیاس زمانی مختلف را بررسی می‌کنیم.

### ۴.۱ میزان استفاده(Utilization)

با توجه به اینکه فیس‌بوک اخیراً به استفاده از اترنت ۱۰-گیگابیت بر ثانیه در تمام میزبان‌های خود روی آورده است، جای تعجب نیست که **میزان استفاده کلی از لینک دسترسی** )یعنی لینک‌های بین میزبان‌ها و RSWآنها (بسیار پایین است، به طوری که میانگین میزان استفاده لینک ۱-دقیقه‌ای کمتر از ۱٪ است. این امر با سطوح استفاده‌ای که برای سایر

مراکز داده در مقیاس ابری گزارش شده است [۱۲، ۱۷]، همخوانی دارد. تقاضا از الگوهای معمول شبانه‌روزی و روزهای هفته پیروی می‌کند، اگرچه میزان تغییر در حدود ۲ برابر است، برخلاف تغییرات در حدود یک بزرگی که در جاهای دیگر گزارش شده است [۱۲]. حتی پربارترین لینک‌ها نیز در مقیاس‌های زمانی ۱-دقیقه‌ای به صورت سبک بارگذاری می‌شوند: ٪۹۹ از تمام لینک‌ها معمولاً کمتر از ٪۱۰ بارگذاری می‌شوند. بار در بین کلاسترها به طور قابل توجهی متفاوت است، به طوری که میانگین میزان استفاده لینک در پربارترین کلاسترها (هدوپ) تقریباً ۵ برابر کلاسترهای با بار سبک (فرانت‌اند) است.

همانند سایر مراکز داده با ساختار مشابه [۱۲، ۱۳]، میزان استفاده در سطوح تجمیع بالاتر افزایش می‌یابد. با تمرکز بر روی لینک‌های بین RSWها وCSW ها، میزان استفاده میانه در بین کلاسترها بین ٪۲۰-۱۰ متفاوت است، و ٪۵ از شلوغ‌ترین لینک‌ها میزان استفاده ٪۴۶-۲۳ را نشان می‌دهند. این سطوح بالاتر از اکثر مراکز داده‌ای است که قبلاً مورد مطالعه قرار گرفته‌اند [۱۲، شکل ۹]، که احتمالاً به دلیل افزایش نامتناسب در تکنولوژی لینک‌های لبه (۱ ⬅ ۱۰ گیگابیت بر ثانیه) در مقابل لینک‌های تجمیع (۱۰ ⬅ ۴۰ گیگابیت بر ثانیه) است. واریانس بین کلاسترها کاهش می‌یابد، به طوری که پربارترین کلاسترها ۳ برابر بیشتر از کلاسترهای سبک‌تر بار دارند. میزان استفاده در لینک‌های بینCSW ها و سوئیچ‌های FC حتی بالاتر است، هرچند تفاوت بین کلاسترها کمتر آشکار است زیرا کلاسترهای مختلف با تعداد متفاوتی از لینک‌های بالاسری بر اساس تقاضای خود، تأمین منابع شده‌اند. ما میزان استفاده لینک را در مقیاس‌های زمانی دقیق‌تر در بخش ۶ بررسی می‌کنیم.

### ۴.۲ محلی‌گرایی و پایداری

مطالعات قبلی محلی‌گرایی سنگین به رک را در ترافیک مرکز داده مشاهده کرده‌اند. این رفتار به نظر می‌رسد با برنامه‌هایی که به دنبال به حداقل رساندن استفاده از شبکه با استفاده از محلی‌گرایی داده هستند، همسو باشد و اجازه می‌دهد توپولوژی‌هایی با سطوح بالای بیش‌فروشی وجود داشته باشند. ما محلی‌گرایی ترافیک فیس‌بوک را از یک نمونه‌برداری نماینده از سیستم‌های تولیدی در زمان‌های مختلف روز بررسی می‌کنیم.

شکل ۴ تفکیک ترافیک خروجی بر اساس مقصد کلاس‌های مختلف سرورها را نشان می‌دهد: یک سرور هدوپ در یک کلاستر هدوپ، یک سرور وب در یک کلاستر فرانت‌اند، و هر دو فالور کش و لیدر کش در یک کلاستر کش. برای هر سرور، ترافیک ثانوی هر کدام به صورت یک نمودار ستونی انباشته نمایش داده می‌شود، با ترافیک محلی به رک به رنگ فیروزه‌ای، ترافیک محلی به کلاستر به رنگ آبی، و ترافیک درون-و بین-مرکز داده‌ای به رنگ سبز.

در میان چهار نوع سرور، هدوپ تاکنون بیشترین تنوع را نشان می‌دهد—هم در سراسر سرورها و هم در طول زمان؛ برخی از ردیابی‌ها فعالیت شبکه قابل توجهی را نشان نمی‌دهند، در حالی که همه ردیابی‌ها هم محلی‌گرایی به رک و هم به کلاستر را نشان می‌دهند، توزیع بین این دو به شدت متفاوت است. در یک ردیابی ده دقیقه‌ای که در طول یک دوره شلوغ ثبت شده است، ٪۹۹.۸ از کل ترافیک ارسال شده توسط سرور به مقصد سرورهای هدوپ دیگر در همان رک هدایت می‌شود (با یک توزیع نسبتاً یکنواخت در داخل رک)؛ تقریباً تمام مابقی به مقصد میزبان‌های دیگری در داخل کلاستر هدایت می‌شود. تنها مقدار ناچیزی از ترافیک کلاستر را ترک می‌کند.

از نظر پراکندگی ترافیک درون-رک (درون-کلاستر)، سرور هدوپ با ٪۱.۵ از سایر سرورها در کلاستر ارتباط برقرار می‌کند—اگرچه تنها ٪۱۷ از رک‌ها بیش از ٪۸۰ ترافیک سرور را دریافت می‌کنند. این الگو با آنچه توسط کندولا و همکاران [۲۶] مشاهده شده است سازگار است، که در آن ترافیک یا محلی به رک است یا به مقصد تقریباً ٪۱۰-۱ از میزبان‌ها در کلاستر می‌رود.

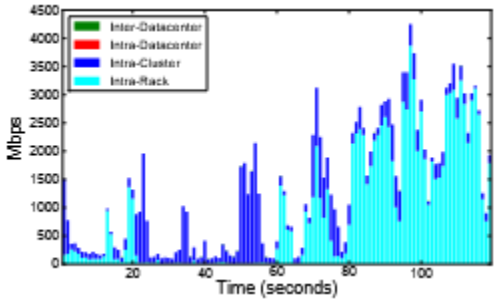
تغییرپذیری هدوپ نتیجه ترکیبی از اندازه شغل و فازهای متمایزی است که یک شغل هدوپ از سر می‌گذراند—هر داده‌ای که ثبت می‌شود ممکن است یک گره هدوپ را در طول یک دوره شلوغ از ترافیک به هم خورده شبکه، یا در طول یک دوره نسبتاً آرام از محاسبات مشاهده کند.

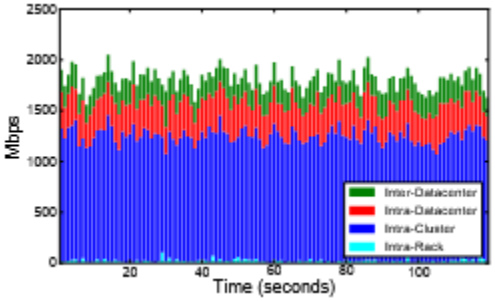
در مقابل، الگوهای ترافیکی برای سایر کلاس‌های سرور هم به وضوح پایدارتر و هم به طرز چشمگیری متفاوت از یافته‌های کندولا و همکاران [۲۶] هستند. قابل توجه است که تنها مقدار حداقلی از ترافیک محلی به رک وجود دارد، حتی ترافیک بین‌مرکز داده‌ای در مقادیر بیشتری وجود دارد. ترافیک کلاستر فرانت‌اند، شامل سرورهای وب و فالورهای کش مربوطه، عمدتاً در داخل کلاستر باقی می‌ماند: ٪۶۸ از ترافیک سرور وب در طول ثبت داده که در اینجا ترسیم شده است، در داخل کلاستر باقی می‌ماند؛ ٪۸۰ آن به سمت سیستم‌های کش هدایت می‌شود؛ سیستم‌های مالتی‌فید و سرورهای SLB هر کدام ٪۸ دریافت می‌کنند. در حالی که ترافیک پس‌زمینه متفرقه وجود دارد، حجم این ترافیک نسبتاً ناچیز است.

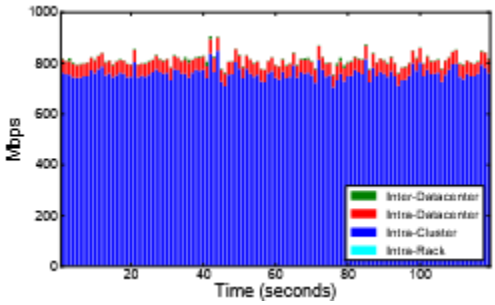
سیستم‌های کش، بسته به نوع، محلی‌گرایی‌های کاملاً متفاوتی را نشان می‌دهند، اگرچه به همراه سرورهای وب، محلی‌گرایی درون-رک حداقل است. فالورهای فرانت‌اند عمدتاً ترافیک را در پاسخ به درخواست‌های سرورهای وب (٪۸۸) ارسال می‌کنند، و بنابراین ترافیک درون-کلاستر بالایی را نشان می‌دهند—که بیشتر به سرویس‌دهی درخواست‌های کش می‌پردازد. به دلیل توازن بار (بخش ۵.۲ را ببینید)، این ترافیک به طور گسترده‌ای پخش می‌شود؛ در طول این بازه زمانی دو دقیقه‌ای، فالور کش با بیش از ٪۷۵ از میزبان‌های کلاستر ارتباط برقرار می‌کند، که شامل بیش

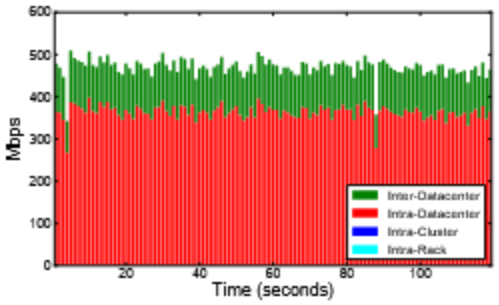
از ۹۰٪ از سرورهای وب است. لیدرهای کش هماهنگی را در سراسر کلاسترها و پایگاه‌های داده پشتیبان حفظ می‌کنند و عمدتاً درگیر ترافیک درون- و بین-مرکز داده‌ای هستند—که یک پیامد ضروری از اینکه کش یک "نمونه توزیع شده جغرافیایی واحد" است، می‌باشد.[15]

پایداری این الگوهای ترافیکی نیاز به اشاره ویژه دارد. در حالی که ترافیک فیس‌بوک تحت تأثیر الگوی شبانه‌روزی که توسط بنسون و همکاران [۱۲] ذکر شده، قرار دارد، نسبت‌های نسبی محلی‌گرایی تغییر نمی‌کند—فقط مقدار کل ترافیک تغییر می‌کند. در دوره‌های زمانی به اندازه کافی کوتاه، نمودار اساساً ثابت و بدون تغییر به نظر می‌رسد. برای بررسی بیشتر علت و جزئیات این پایداری، توجه خود را به خود ماتریس ترافیک معطوف می‌کنیم.




شکل ۴: محلی‌گرایی ترافیک در هر ثانیه بر اساس نوع سیستم در یک بازه دو دقیقه‌ای: هدوپ (بالا چپ)، سرور وب (بالا راست)، فالور کش (پایین چپ) و لیدر (پایین راست) (توجه: محورهای y متفاوت هستند)

| Locality | All | Hadoop | FE | Svc. | Cache | DB |
|---|---|---|---|---|---|---|
| Rack | 12.9 | 13.3 | 2.7 | 12.1 | 0.2 | 0 |
| Cluster | 57.5 | 80.9 | 81.3 | 56.3 | 13.0 | 30.7 |
| DC | 11.9 | 3.3 | 7.3 | 15.7 | 40.7 | 34.5 |
| Inter-DC | 17.7 | 2.5 | 8.6 | 15.9 | 16.1 | 34.8 |
| Percentage | | 23.7 | 21.5 | 18.0 | 10.2 | 5.2 |

جدول ۳: کلاسترهای مختلف، محلی‌گرایی‌های متفاوتی دارند؛ ردیف آخر سهم هر کلاستر در کل ترافیک شبکه را نشان می‌دهد.

### ۴.۳ ماتریس ترافیک

با توجه به نبود شگفت‌انگیز محلی‌گرایی به رک و درجه بالای پایداری ترافیک، ما ترافیک را از منظر بلندمدت‌تر و با نمای بازتر که توسط Fbflowفراهم شده است، بررسی می‌کنیم. جدول ۳ محلی‌گرایی ترافیک تولید شده توسط تمام ماشین‌های فیس‌بوک را در یک دوره ۲۴ ساعته در ژانویه ۲۰۱۵، همانطور که توسط Fbflow گزارش شده، نشان می‌دهد. الگوهای ترافیکی فیس‌بوک به صورت روزانه پایدار باقی می‌مانند—برخلاف مرکز داده‌ای که توسط دلیمیترو و همکاران [۱۷] مطالعه شده است. اکثریت واضح ترافیک **درون-کلاستر است اما درون-رک نیست** (یعنی ترافیکی که در داخل یک رک باقی می‌ماند، در ۵۷.۵٪ از ترافیک با عنوان درون-کلاستر شمرده نمی‌شود). علاوه بر این، ترافیک بیشتری بین مراکز داده عبور می‌کند تا در داخل یک رک باقی بماند.

جدول ۳ محلی‌گرایی ترافیک تولید شده توسط پنج نوع کلاستر برتر را که در مجموع ۷۸.۶٪ از ترافیک در شبکه فیس‌بوک را تشکیل می‌دهند، بیشتر تفکیک می‌کند. کلاسترهای هدوپ بیشترین ترافیک (۲۳.۷٪ از کل ترافیک) را تولید می‌کنند و به طور قابل توجهی از سایرین بیشتر محلی به رک هستند، اما حتی ترافیک آن‌ها نیز بسیار با ۸۰٪-۴۰ محلی به رک که در ادبیات گزارش شده است [۱۲، ۱۷]، فاصله دارد. در عوض، ترافیک هدوپ به وضوح **محلی به کلاستر** است.

این تمایز به وضوح در شکل ۵، که به سبک دلیمیترو و همکاران [۱۷] تولید شده است، نشان داده شده است. دو قسمت سمت چپ شکل، تقاضای ترافیک نسبی بین ۶۴ رک در داخل کلاسترهای دو نوع مختلف را نشان می‌دهد. در حالی که ما فقط یک زیرمجموعه از کل مجموعه رک‌ها را در هر کلاستر نشان می‌دهیم، الگو نماینده کل کلاستر است.

ترافیک درون کلاستر هدوپ (سمت چپ) با یک **قطر قوی** (یعنی محلی‌گرایی درون-رک) همگن است. یکنواختی در سطح کلاستر در خارج از رک محلی، بیش از ٪۸۰ از ترافیک درون-کلاستر هدوپ را تشکیل می‌دهد—حتی اگر ترافیک به رک محلی بر هر رک مشخصی به صورت ایزوله غالب باشد. وظایف Map به گونه‌ای قرار داده می‌شوند که محلی‌گرایی خواندن را به حداکثر برسانند، اما تعداد زیادی از وظایف همزمان به این معنی است که ممکن است یک وظیفه مشخص به طور کامل در داخل یک رک جای نگیرد. بنابراین، مقداری ترافیک به طور ضروری باید رک را در طول فازهای درهم‌آمیختن و خروجی یک وظیفه MapReduceترک کند. علاوه بر این، کلاستر به سرورهای دیگری داده درخواست می‌کند که ممکن است برای دستیابی به محلی‌گرایی خواندن تلاش زیادی نکنند، که این نیز به کاهش محلی‌گرایی به رک کمک می‌کند.

کلاستر فرانت‌اند (مرکز) الگوهای متفاوتی را بر اساس نوع رک نشان می‌دهد، به طوری که هیچ‌کدام به طور خاص محلی به رک نیستند. به طور خاص، ما یک **الگوی ترافیک دوپارته (bipartite)** قوی بین سرورهای وب و فالورهای کش مشاهده می‌کنیم. سرورهای وب به صورت دوطرفه با سرورهای کش ارتباط برقرار می‌کنند و بالعکس، و سرورهایی با انواع مختلف در رک‌های متمایزی مستقر می‌شوند که منجر به ترافیک درون-رک کمی می‌شود. این تفاوت قابل توجه در محلی‌گرایی فیس‌بوک در مقایسه با برنامه‌های قبلی که بر اساس اینترنت مطالعه شده‌اند، پیامد واقعیت سرویس‌دهی به یک نمودار اجتماعی به شدت متصل است. اشیاء کش در سراسر کلاسترها تکثیر می‌شوند؛ با این حال، هر شیء به طور معمول فقط در یک خوشه (گرچه اشیاء داغ تکثیر می‌شوند تا از نقاط داغ جلوگیری شود، که در بخش ۵ درباره آن بحث می‌کنیم). از آنجایی که هر سرور وب نیاز دارد بتواند هر درخواستی را پاسخ دهد، ممکن است لازم باشد به داده‌ها به شیوه‌ای بالقوه تصادفی به دلیل توازن بار دسترسی پیدا کنند. برای ملموس‌تر کردن این استدلال، فید خبری فیس‌بوک از آرایه‌ای وسیع از اشیاء مختلف در نمودار اجتماعی داده می‌گیرد: افراد مختلف، روابط، و رویدادها یک نمودار بزرگ به هم پیوسته را به شیوه‌ای پیچیده تشکیل می‌دهند. این پیوستگی به این معنی است که مجموعه کاری احتمالاً کوچک نخواهد بود، حتی اگر کاربران تقسیم‌بندی شوند، و نتیجه خالص، نرخ موفقیت پایین کش در داخل رک است که منجر به محلی‌گرایی بالای ترافیک درون-کلاستر می‌شود. علاوه بر این، تقسیم‌بندی نمودار به گونه‌ای که کاربران و داده‌هایشان در یک مکان مشترک در رک‌ها قرار بگیرند، پتانسیل معرفی حالت‌های خرابی را دارد که به طور نامتناسبی زیرمجموعه‌های هدف از پایگاه کاربران را تحت تأثیر قرار می‌دهند و منجر به یک تجربه نامطلوب می‌شود.

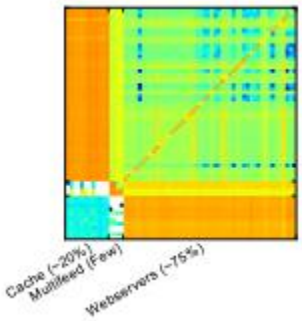
سه نوع کلاستر دیگر نیز رفتارهای متمایز اضافی را نشان می‌دهند (نشان داده نشده است). به عنوان مثال، ترافیک در کلاسترهای لیدر کش، تقاضای درون-رکی بسیار کمی دارد و به جای آن، تمام ترافیک خود را در سراسر مرکز داده پخش می‌کند. ترافیک در کلاسترهای پایگاه داده بک‌اند، یکنواخت‌ترین است و تقریباً به طور مساوی در میان گره‌های درون کلاستر، در همان مرکز داده و در سطح جهانی تقسیم می‌شود. کلاسترهای سرویس، که میزبان رک‌هایی هستند که از طیف گسترده‌ای از سرویس‌های پشتیبانی‌کننده پشتیبانی می‌کنند، یک الگوی ترافیکی مختلط را در این نقاط افراطی نشان می‌دهند.

ارتباط بین-کلاستری به طور قابل توجهی بر اساس نوع کلاستر متفاوت است. شکل c۵ نمودار تقاضای ترافیک را بین ۱۵ کلاستر در یک مرکز داده واحد برای یک دوره ۲۴ ساعته نشان می‌دهد. کلاسترهای هدوپ، به عنوان مثال، سهم بسیار کوچکی از ترافیک درون-کلاستری دارند، در حالی که کلاسترهای کش مقدار زیادی ترافیک بین-کلاستری دارند که بین فالورهای کش در کلاسترهای دیگر و کلاسترهای پایگاه داده تقسیم می‌شود. در حالی که هر کلاستر ممکن است ساختار ۴-پستی مشابهی را به صورت داخلی داشته باشد، ممکن است منطقی باشد که ارتباط بین-کلاستری ناهمگن را در نظر بگیریم، زیرا تقاضا در بین جفت کلاسترها در بیش از هفت مرتبه بزرگی متفاوت است.

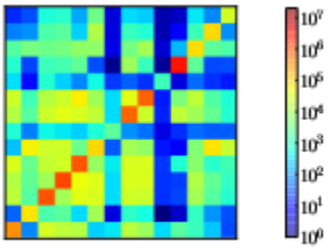
در حالی که کلاستر ۴-پستی در مراکز داده فیس‌بوک همچنان غالب است، فیس‌بوک اخیراً یک شبکه جدید را اعلام کرده است توپولوژی‌ای که در مراکز داده در حال اجراست [۹]. در حالی که سرورها دیگر به صورت فیزیکی در کلاسترها گروه‌بندی نمی‌شوند (در عوض، آن‌ها شامل پادهایی هستند که تمام پادها در یک مرکز داده اتصال‌پذیری بالایی دارند)، مفهوم منطقی سطح بالای یک کلاستر برای اهداف مدیریت سرور همچنان برای تسهیل گذار وجود دارد. بر این اساس، ماتریس ترافیک رک به رک یک کلاستر فرانت‌اند در داخل یکی از مراکز داده جدید بافت در یک دوره یک روزه (که نشان داده نشده است) شبیه به آنچه در شکل ۵ نشان داده شده است، به نظر می‌رسد.



الف) رک به رک، کلاستر هدوپ



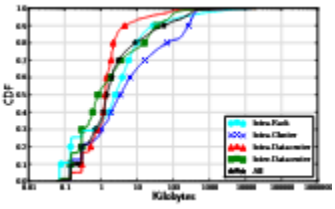

ب) رک به رک، کلاستر فرانت‌اند



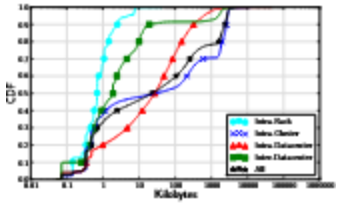
ج) کلاستر به کلاستر

**شکل ۵ :تقاضای ترافیک بر اساس مبدأ (محورx ) و مقصد(محور y).**

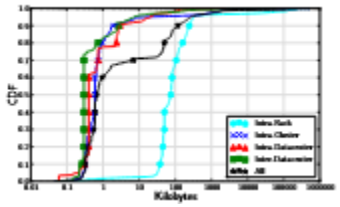
نمودارها هر کدام بر اساس کمترین تقاضا در آن نوع نمودار نرمال‌سازی شده‌اند (یعنی کلاسترهای هدوپ و فرانت‌اند به یک مقدار یکسان نرمال‌سازی شده‌اند، در حالی که نمودار کلاستر به کلاستر به طور مستقل نرمال‌سازی شده است).



الف) وب سرورها

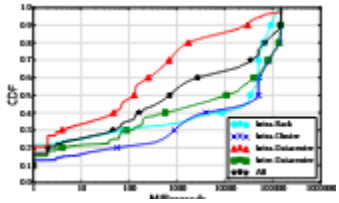


ب) فالور کش

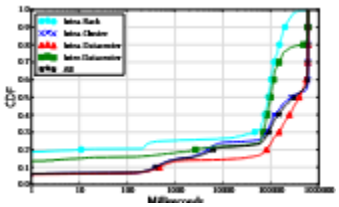


ج) هد هوپ

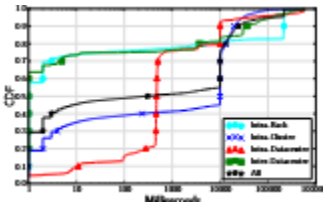
شکل ۶: توزیع اندازه جریان، تفکیک شده بر اساس مکان مقصد



الف) وب سرورها



ب) فالور کش



ج) هد هوپ

شکل ۷: توزیع مدت زمان جریان، تفکیک شده بر اساس مکان مقصد

### ۴.۴ پیامدها برای بافت‌های اتصال

سطوح پایین استفاده که در لبه شبکه یافت شد، رویه معمول بیش‌فروشی لایه‌های تجمیع و هسته شبکه را تقویت می‌کند، هرچند هنوز مشخص نیست که آیا با گذشت عمر مراکز داده، میزان استفاده نیز افزایش خواهد یافت یا خیر. ویژگی‌های محلی‌گرایی بسیار متضاد کلاسترهای مختلف به این معنی است که یک توپولوژی همگن واحد یا در برخی مناطق بیش از حد تأمین منابع می‌شود یا در برخی دیگر با ازدحام مواجه است—یا هر دو. این واقعیت استدلال می‌کند که فناوری‌های بافت ناهمگون که می‌توانند پهنای باند بالاتری را به مکان‌های خاصی نسبت به سایرین ارائه دهند، ممکن است کاربرد داشته باشند. محققان در حال بررسی تکنیک‌هایی برای کاهش نقاط داغ ترافیکی هستند. با این حال، پایداری الگوهای ترافیکی که ما مشاهده می‌کنیم، نشان می‌دهد که قابلیت پیکربندی سریع ممکن است آنقدر که برخی تصور کرده‌اند، ضروری نباشد.

تا حدودی شگفت‌آور است که فقدان سطوح قابل توجهی از محلی‌گرایی درون-رک (به جز در کلاستر هدوپ) اشاره دارد کهRSW ها (یعنی سوئیچ‌های بالای رک) که اتصال‌پذیری غیر مسدودکننده و کامل با نرخ خط را بین تمام پورت‌های خود ارائه نمی‌دهند، ممکن است قابل دوام باشند. به طور خاص، الگوی ترافیک دوپارته بین میزبان‌های نهایی و لینک‌های بالاسری RSW ممکن است بهینه‌سازی‌هایی را در طراحی سوئیچ امکان‌پذیر سازد. ما در بخش ۶ برای بررسی پیامدهای بیشتر برای طراحی سوئیچ باز می‌گردیم.

## ۵ .مهندسی ترافیک

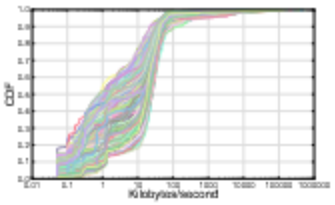
مطالعات قبلی نشان می‌دهند که پایداری ترافیک مرکز داده به مقیاس زمانی مشاهده وابسته است. در این بخش، ما ترافیک فیس‌بوک را در مقیاس‌های زمانی دقیق تحلیل می‌کنیم، با نگاهی به درک اینکه رویکردهای مختلف مهندسی ترافیک و توازن بار چگونه تحت چنین شرایطی می‌توانند قابل استفاده باشند.

### ۵.۱ مشخصات جریان‌ها

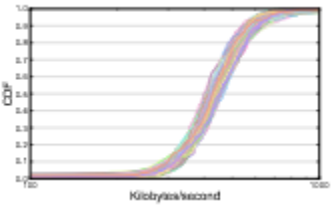
شکل‌های ۶ و ۷ به ترتیب اندازه و مدت زمان جریان‌ها (که توسط ۵-تاپل تعریف شده‌اند) را که در یک بازه ۱۰ دقیقه‌ای (۲.۵ دقیقه برای قفسه سرور وب) از ردیابی‌های بسته سه نوع گره مختلف جمع‌آوری شده‌اند، ترسیم می‌کنند: یک قفسه سرور وب، یک فالور کش واحد (لیدر کش شبیه به فالور است و به دلیل محدودیت‌های فضا نشان داده نشده است)، و یک گره هدوپ. ما توزیع کلی (به رنگ سیاه) و همچنین منحنی‌های مربوط به مقصد را نشان می‌دهیم. مطابق با ادبیات علمی [۲۶، شکل ۹]، ما دریافتیم که بیشتر جریان‌ها در کلاستر هدوپ فیس‌بوک کوتاه هستند. همانطور که قبلاً بحث شد، تقاضاهای ترافیکی هدوپ به طور قابل توجهی در بین گره‌ها و زمان‌ها متفاوت است. ما نتایج را از ردیابی یک گره در یک بازه زمانی ۱۰ دقیقه‌ای نسبتاً شلوغ ترسیم می‌کنیم؛ ردیابی‌ها از گره‌های دیگر یا حتی همان گره در زمان‌های مختلف توزیع‌های تا حدودی متفاوتی را نشان می‌دهند، بنابراین ما در مورد بررسی بیش از حد دقیق توزیع خاص هشدار می‌دهیم. حتی در بازه زمانی نمودار شده، ٪۷۰ از جریان‌ها کمتر از ۱۰ کیلوبایت داده ارسال می‌کنند و کمتر از ۱۰ ثانیه طول می‌کشند؛ میانگین جریان‌ها کمتر از ۱ کیلوبایت داده ارسال کرده و کمتر از یک ثانیه طول می‌کشند. کمتر از ٪۵ از جریان‌ها بزرگتر از ۱ مگابایت یا طولانی‌تر از ۱۰۰ ثانیه هستند؛ تقریباً هیچ‌کدام از آن‌ها از بازه زمانی ۱۰ دقیقه‌ای ما فراتر نمی‌روند.

برعکس، ردیابی‌های انواع دیگر سرویس‌ها به دلیل توازن بار بسیار نماینده‌تر هستند. علاوه بر این، بسیاری از سرویس‌های داخلی فیس‌بوک از نوعی **پویش اتصالی** [29] **(connection pooling)** استفاده می‌کنند، که منجر به اتصالات با عمر طولانی و پهنای باند نسبتاً پایین می‌شود. پویش به ویژه در گره‌های فالور کش (لیدر، که نشان داده نشده است) رایج است، جایی که تنها ۳۰(۴۰)٪ از جریان‌ها کمتر از ۱۰۰ ثانیه طول دارند و بیش از ۴۰(۲۵)٪ از جریان‌ها از دوره ثبت ۱۰ دقیقه‌ای ما فراتر می‌روند. با این گفته، بیشتر جریان‌ها تنها در طول بازه‌های زمانی مشخص در مقیاس میلی‌ثانیه با شکاف‌های بزرگ در میان آن‌ها فعال هستند (یعنی بسته‌ها را واقعاً ارسال می‌کنند). به عبارت دیگر، صرف نظر از اندازه یا طول جریان، آن‌ها تمایل دارند که به صورت داخلی ناگهانی (bursty)باشند. به طور کلی، جریان‌های کش نیز به طور قابل توجهی بزرگتر از هدوپ هستند؛ در حالی که سرورهای وب جایی در وسط قرار می‌گیرند.

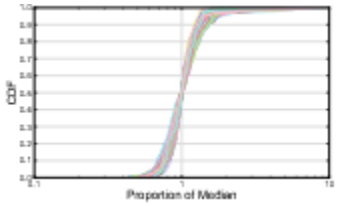
اگر سطوح بالاتری از تجمیع را در نظر بگیریم، یعنی گروه‌بندی جریان‌ها به سادگی بر اساس میزبان یا قفسه مقصد، توزیع اندازه‌های جریان به سادگی برای سرورهای وب به سمت راست منتقل می‌شود (و شکل اصلی خود را حفظ می‌کند). با این حال، رفتار برای فالورهای کش به شدت متفاوت است: توزیع گسترده اندازه جریان که در سطح ۵-تاپل آشکار است (شکل ۶ب)، در سطوح میزبان و قفسه ناپدید می‌شود و با یک توزیع بسیار فشرده در حدود ۱ مگابایت برای هر میزبان جایگزین می‌گردد (شکل ۹ را ببینید). این امر پیامد تصمیم برای توازن بار درخواست‌های کاربران ورودی در سراسر سرورهای وب، همراه با تعداد زیاد درخواست‌های کاربر است. از آنجا که درخواست‌ها و پاسخ‌ها معمولاً کوچک هستند (در حدود چند کیلوبایت)، ما هیچ عدم تعادلی که توسط اندازه‌های پاسخ نابرابر ایجاد شود، مشاهده نمی‌کنیم.




الف) هدوپ (نرخ، هر سری ۱ ثانیه است)

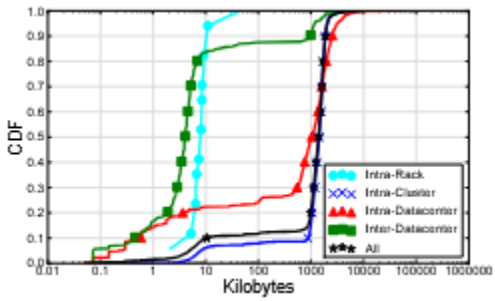



ب) کش (نرخ، هر سری ۱ ثانیه است)




ج) کش (پایداری، هر سری یک قفسه است)

شکل ۸: توزیع نرخ جریان به ازای هر رک مقصد (هم برای هدوپ و هم کش) و پایداری (کش)




شکل ۹: اندازه جریان به ازای هر میزبان در فالور کش

### ۵.۲ توازن بار

تلاش‌های موجود در مهندسی ترافیک به دنبال استفاده از تغییرپذیری ترافیک هستند؛ ترافیک بسیار منظم فرصت زیادی برای بهبود ارائه نمی‌دهد. در بخش قبلی، ما اشاره کردیم که رویکرد فیس‌بوک به توازن بار در مقیاس‌های زمانی بزرگ (از دقیقه تا ساعت) بسیار مؤثر است و فضای کمی برای مهندسی ترافیک باقی می‌گذارد. اکنون ما ویژگی‌های ترافیک را در طول چند ثانیه در نظر می‌گیریم تا تعیین کنیم آیا مهندسی ترافیک می‌تواند در مقیاس‌های زمانی کوتاه مؤثر باشد یا خیر.

ما بررسی می‌کنیم که چگونه ترافیک از یک میزبان از یک ثانیه به ثانیه دیگر تغییر می‌کند. ما توزیع نرخ جریان‌ها را در هر ثانیه، که بر اساس رک مقصد تجمیع شده است، بررسی کرده و هر ثانیه را با ثانیه بعدی مقایسه می‌کنیم. به صورت شهودی، هرچه توازن بار بهتر باشد، هر ثانیه به ثانیه بعدی نزدیک‌تر به نظر می‌رسد.

ما ابتدا کلاستر هدوپ را با نگاه به ۱۲۰ ثانیه متوالی بررسی می‌کنیم. شکل ۸الف نمودار CDF اندازه‌های جریان به ازای هر رک مقصد را برای هر بازه (یعنی ۱۲۰ منحنی جداگانه) ترسیم می‌کند. در حالی که ما ادعا نمی‌کنیم که این سرور خاص نماینده است، اما توزیع‌های نرخ جریان بسیار متغیری (یعنی بیش از سه مرتبه بزرگی) را نشان می‌دهد که در مشاهدات ما رایج است.

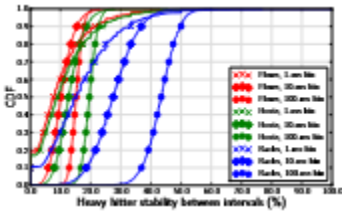
این امر به خودی خود، غیرمنتظره نیست—هدوپ دوره‌هایی از ترافیک شبکه متغیر را دارد، و یک کلاستر تولیدی می‌تواند ترکیبی از کارهای مختلف را اجرا کند. این تغییرپذیری ترافیک به این معنی است که طرح‌های مهندسی ترافیک موجود به دنبال استفاده از این مزیت هستند . **Orchestra [16]**بر تغییرات زمانی و به ازای هر کار تکیه می‌کند تا زمان تکمیل وظایف با اولویت بالا را کاهش دهد، در حالی که **Hedera [5]**برای جریان‌های فیل سنگین پهنای باند بالا که برای چند ثانیه ادامه دارند، فراهم کردن مسیر غیرقابل مسیریابی را فراهم می‌کند که در بارهای کاری هدوپ رایج است.

داستان متفاوتی برای ترافیک فرانت‌اند، و به ویژه کش، پدیدار می‌شود. از جدول ۲ می‌فهمیم که بزرگترین سهم ترافیک فالور کش، پاسخ‌هایی است که به سرورهای وب بازمی‌گردد. شکل ۸ب توزیع نرخ جریان‌های در هر ثانیه را بر اساس هر رک از یک گره فالور کش واحد در یک بازه زمانی دو دقیقه‌ای نشان می‌دهد. توزیع‌ها برای هر یک از ۱۲۰ ثانیه مشابه هستند، یعنی CDF ها در حدود میانه (تقریباً ۲ مگابیت بر ثانیه) نسبتاً عمودی هستند. الگوهای مشابه (با مقیاس‌های مختلف) برای سرویس‌های دیگر نیز مشاهده می‌شود.

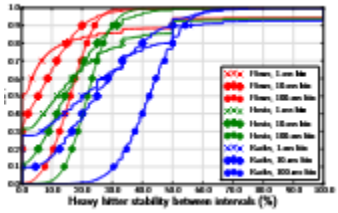
از دیدگاه یک میزبان واحد، هر ثانیه مشابه به ثانیه بعدی است. با این حال، این تحلیل تنوع به ازای هر مقصد را در نظر نمی‌گیرد. قابل تصور است که می‌تواند جریان‌های مقصد با نرخ بالا یا نرخ پایین وجود داشته باشد که به طور بالقوه می‌تواند توسط یک طرح مهندسی ترافیک به صورت متفاوتی مورد بررسی قرار گیرد. برای هر میزبان، ما نرخ ترافیک خروجی را به ازای هر رک مقصد (که بر اساس نرخ میانه برای آن رک نرمال‌سازی شده است) در نظر می‌گیریم و نرخ را در طول زمان برای هر رک ردیابی می‌کنیم. شکل ۸ج این توزیع‌ها را برای ترافیک خروجی برای همان

ماشین کش که در شکل ۸ب است، ترسیم می‌کند. ما دریافتیم که اندازه‌های جریان به ازای هر رک مقصد به طرز قابل توجهی نه تنها در سراسر ثانیه‌ها، بلکه در فواصل زمانی به طول ۱۰ ثانیه نیز پایدار هستند (نشان داده نشده است). تمام جریان‌ها در حدود ٪۹۰ از بازه‌های ۱-ثانیه‌ای در فاکتوری از دو از اندازه میانه خود هستند—جریان میانه تنها در ٪۴۵ از بازه‌های ۱-ثانیه‌ای "تغییر قابل توجهی" را نشان می‌دهد، طبق برش انحراف ٪۲۰ که توسط بنسون و همکاران [۱۴] تعریف شده است. این امر در تضاد با ترافیک گره هدوپ است—که توازن بار نشده است—جایی که میانه ٪۹۰ از جریان‌ها می‌تواند در اندازه‌ای با بیش از شش مرتبه بزرگی در مقایسه با اندازه میانه آن‌ها در ردیابی متفاوت باشد (نشان داده نشده است).

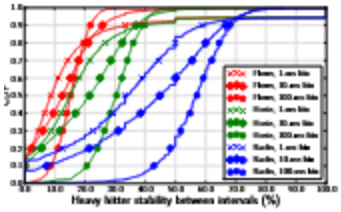
چنین پایداری، هم در طول زمان و هم بر اساس مقصد، نتیجه ترکیبی از ویژگی‌های بار کاری و تلاش مهندسی است. در یک سیستم کش، بار ارائه شده در هر ثانیه به طور تقریبی ثابت نگه داشته می‌شود—افزایش‌های بزرگ در بار نشان‌دهنده اشیاء نسبتاً داغ است که به طور فعال نظارت و کاهش داده می‌شوند. افزایش ناگهانی درخواست‌ها برای یک شیء خاص، سرور کش را هدایت می‌کند تا به سرور وب دستور دهد شیء داغ را به طور موقت کش کند؛ افزایش ناگهانی برای شیء منجر به تکثیر شیء یا شارد محصورکننده در سراسر چندین سرور کش برای کمک به پخش بار می‌شود. ما همچنین اشاره می‌کنیم که توزیع نرخ درخواست برای ۵۰ شیء پرتقاضا در سراسر تمام سرورهای کش نزدیک به هم است و طول عمر میانه برای اشیاء در این لیست در حدود چند دقیقه است. پایداری ترافیک به ازای هر مقصد دوباره نتیجه‌ای از چندگانه شدن درخواست‌های کاربر در سراسر سرورهای وب موجود، همراه با جفت‌های درخواست/پاسخ نسبتاً کوچک است.



الف) فالور کش



ب) لیدر کش



ج) سرورهای وب

شکل ۱۰: پایداری ترافیک‌های سنگین به عنوان تابعی از تجمیع برای پنجره‌های زمانی ۱/۱۰/۱۰۰-میلی‌ثانیه

| Type | | Number | | | Size (Mbps) | | |
|---|---|---|---|---|---|---|---|
| | | p10 | p50 | p90 | p10 | p50 | p90 |
| Web | f | 1 | 4 | 15 | 1.6 | 3.2 | 47.3 |
| | h | 1 | 4 | 14 | 1.6 | 3.3 | 48.1 |
| | r | 1 | 3 | 9 | 1.7 | 4.6 | 48.9 |
| Cache (f) | f | 8 | 19 | 35 | 5.1 | 9.0 | 22.5 |
| | h | 8 | 19 | 33 | 8.4 | 9.7 | 23.6 |
| | r | 7 | 15 | 23 | 8.4 | 14.5 | 31.0 |
| Cache (l) | f | 1 | 16 | 48 | 2.6 | 3.3 | 408 |
| | h | 1 | 8 | 25 | 3.2 | 8.1 | 414 |
| | r | 1 | 7 | 17 | 5 | 12.6 | 427 |
| Hadoop | f | 1 | 2 | 3 | 4.6 | 12.7 | 1392 |
| | h | 1 | 2 | 3 | 4.6 | 12.7 | 1392 |
| | r | 1 | 2 | 3 | 4.6 | 12.7 | 1392 |

جدول ۴: تعداد و اندازه ترافیک‌های سنگین در بازه‌های ۱-میلی‌ثانیه برای هر یک از سطوح تجمیع جریان (f)، میزبان (h)، و رک (r).

### ۵.۳ ترافیک‌های سنگین

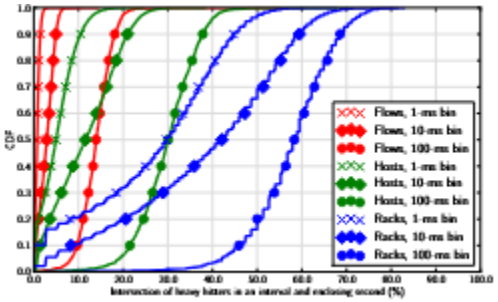
در این بخش، ما رفتار ترافیک را در مقیاس‌های زمانی زیر-ثانیه بررسی می‌کنیم تا پایداری آن و امکان کاربرد مهندسی ترافیک را بهتر درک کنیم. به طور خاص، ما می‌خواهیم ببینیم که آیا جریان‌های خاصی (تجمیع‌شده یا نه) از نظر نرخ برجسته هستند، زیرا چنین جریان‌هایی بزرگترین فرصت را برای تأثیر بالقوه بر عملکرد شبکه فراهم می‌کنند.

ما مجموعه‌ای از جریان‌ها را که آن‌ها را **ترافیک‌های سنگین (heavy hitters)** می‌نامیم، تعریف می‌کنیم. این ترافیک‌ها نمایانگر حداقل مجموعه‌ای از جریان‌ها (یا میزبان‌ها یا رک‌ها) هستند که مسئول ٪۵۰ از حجم ترافیک مشاهده‌شده (بر حسب بایت) در یک بازه زمانی ثابت هستند. به صورت شهودی، وجود ترافیک‌های سنگین می‌تواند نشان‌دهنده یک عدم تعادل باشد که می‌توان بر روی آن عمل کرد—اگر آن‌ها برای مدت زمان کافی مداوم و به اندازه کافی بزرگ باشند که در مقایسه با سایر جریان‌ها، رفتار متفاوت با آن‌ها تفاوت ایجاد کند.

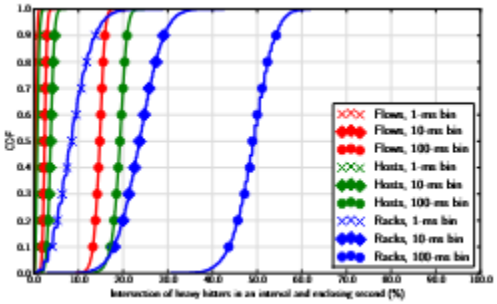
جدول ۴ آمار مربوط به تعداد و اندازه ترافیک‌های سنگینی را نشان می‌دهد که ٪۵۰ از ترافیک را در بازه‌های ۱-میلی‌ثانیه برای هر چهار کلاس سرور تشکیل می‌دهند. از آنجا که ما به جریان‌های بزرگ آنی

علاقه‌مند هستیم، اندازه را بر حسب نرخ و نه تعداد بایت‌های ارسال شده در طول عمر جریان اندازه‌گیری می‌کنیم. در ادامه، ما طول عمر ترافیک‌های سنگین را بررسی می‌کنیم، که بر اساس ۵-تاپل، میزبان مقصد و رک تجمیع شده‌اند و در بازه‌های ۱، ۱۰ و ۱۰۰ میلی‌ثانیه اندازه‌گیری شده‌اند. شکل ۱۰ کسری از ترافیک‌های سنگین را نشان می‌دهد که در بازه‌های زمانی بعدی باقی می‌مانند. ما گره‌های هدوپ را نشان نمی‌دهیم، زیرا تعریف ما از ترافیک سنگین تقریباً همیشه منجر به شناسایی ۱ تا ۳ ترافیک سنگین در هر سطح تجمیع جریان، میزبان و رک در تمام سه بازه زمانی می‌شود.

ماندگاری ترافیک سنگین برای جریان‌های فردی پایین است (قرمز): در حالت میانه، بیش از تقریباً ۱۵٪ از جریان‌ها صرف نظر از طول دوره، باقی نمی‌مانند، که نتیجه ناگهانی بودن داخلی جریان‌ها است که قبلاً ذکر شد. تجمیع در سطح میزبان (سبز) کمی بهتر عمل می‌کند؛ با این حال، با استثنای تجمیع در سطح میزبان مقصد برای سرورهای وب، بیش از ۲۰٪ از میزبان‌های ترافیک سنگین در یک بازه زمانی زیر-ثانیه به عنوان یک ترافیک سنگین در بازه بعدی باقی نمی‌مانند. سرورهای وب نرخ بالاتری در طول دوره‌های ۱۰۰-میلی‌ثانیه دارند، زیرا تعداد نسبتاً کمی از سرورهای کش و توزیع‌کننده‌های بار دارند که با آن‌ها ارتباط برقرار می‌کنند، در حالی که سرورهای کش با بسیاری از سرورهای وب مختلف ارتباط برقرار می‌کنند.




الف) سرور وب




الف) فالور کش

**شکل ۱۱ :**اشتراک بین ترافیک‌های سنگین در یک زیربازه با بازه ثانیه‌ای دربرگیرنده

این موضوع تا زمانی که جریان‌های در سطح رک (آبی) در نظر گرفته نشود، آشکار نمی‌شود که ترافیک‌های سنگین به طور خاص پایدار هستند. در حالت میانه، بیش از ۴۰٪ از ترافیک‌های سنگین کش در بازه زمانی ۱۰۰-میلی‌ثانیه بعدی باقی می‌مانند، و این مقدار برای سرورهای وب تقریباً ۶۰٪ است. ترافیک‌های سنگین از سرورهای وب به طور کلی پایدارتر هستند، به طوری که ۳۲٪ از ترافیک‌های سنگین در سطح رک در حالت میانه بازه ۱-میلی‌ثانیه باقی می‌مانند. با این وجود، ماندگاری ترافیک سنگین به طور خاص برای مهندسی ترافیک مطلوب نیست. با شانس نزدیک به ۵۰٪ برای ادامه یک ترافیک سنگین مشخص در دوره زمانی بعدی، پیش‌بینی یک ترافیک سنگین با مشاهده، خیلی مؤثرتر از حدس زدن تصادفی نیست.

حتی اگر کسی بتواند ترافیک‌های سنگین را به طور کامل در مقیاس زمانی ثانیه به ثانیه پیش‌بینی کند، همچنان باید در نظر گرفت که آن دانش چقدر مفید خواهد بود. ما ترافیک‌های سنگین را از فواصل زمانی یک ثانیه‌ای دربرگیرنده، با ترافیک‌های سنگین آنی از هر یک از زیربازه‌ها در یک ثانیه مقایسه می‌کنیم تا ببینیم چه کسری از ترافیک‌های سنگین در یک زیربازه، ترافیک‌های سنگین در سراسر کل بازه یک ثانیه‌ای دربرگیرنده هستند. درجه محدودی از همپوشانی سه چیز را نشان می‌دهد: اول، یک حد بالایی بر اثربخشی مهندسی ترافیک ایجاد می‌کند—مقدار قابل توجهی از ترافیک‌های سنگین زودگذر از دید سیستم مهندسی ترافیک پنهان و بدون درمان باقی می‌ماند. دوم، به عنوان یک شاخص از دشواری پیش‌بینی در وهله اول عمل می‌کند؛ اگر یک بازه پیش‌بینی یک ثانیه‌ای کافی نباشد، ممکن است به مقیاس‌های زمانی کوچک‌تر (که منابع بیشتری مصرف می‌کنند) نیاز باشد. در نهایت، این معیار یک شاخص از ناگهانی بودن (burstiness) است، زیرا نشان‌دهنده حضور تعداد زیادی از ترافیک‌های سنگین زودگذر است.

شکل ۱۱ یک CDF از کسری از کل ترافیک‌های سنگین یک ثانیه را ترسیم می‌کند که در هر بازه ۱۰۰/۱۰/۱-میلی‌ثانیه در داخل ثانیه به صورت آنی سنگین هستند. ما نتایج را برای یک سرور وب و یک فالور کش نشان می‌دهیم—لیدرهای کش مشابه هستند. در دقت ۵-تاپلی، قدرت پیش‌بینی بسیار ضعیف است و کمتر از ۱۵٪-۱۰ است. پیش‌بینی‌های در سطح رک بسیار مؤثرتر هستند، به طوری که ترافیک‌های سنگین در اکثر بازه‌های ۱۰۰-میلی‌ثانیه در حالت میانه برای هر دو سرویس سنگین باقی می‌مانند. پیش‌بینی‌های در سطح میزبان برای سرورهای وب مفیدتر از گره‌های کش هستند، اما تنها حالت ۱۰۰-میلی‌ثانیه بیش از ۳۰٪ مؤثر است.

### ۵.۴ پیامدها برای مهندسی ترافیک

استفاده گسترده فیس‌بوک از **پویش اتصالی (connection pooling)** منجر به جریان‌های با عمر طولانی می‌شود که به نظر می‌رسد نامزدهای بالقوه‌ای برای مهندسی ترافیک هستند. همین سرویس‌ها از توازن بار در سطح برنامه برای دستیابی به تأثیر بزرگ استفاده می‌کنند، با این حال، فضای محدودی برای رویکردهای درون-شبکه‌ای باقی می‌گذارند. بسیاری از تکنیک‌های موجود از طریق شناسایی **ترافیک‌های سنگین (heavy hitters)** و سپس رفتار متفاوت با آن‌ها (مانند: تأمین یک مدار، انتقال آن‌ها به یک لینک با بار سبک، به کارگیری استراتژی‌های بافرینگ جایگزین، و غیره) به دنبال کار کردن هستند. با این حال، برای هر طرحی که بخواهد کار کند، باید ابتدا امکان شناسایی ترافیک‌های سنگین وجود داشته باشد، و سپس بتوان از آن بهره برد.

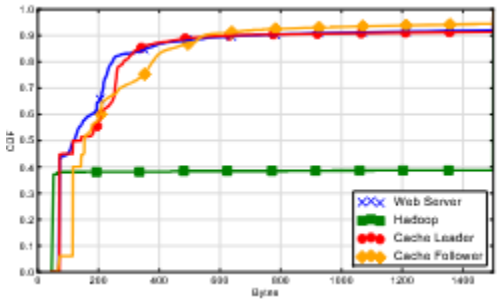
متأسفانه، به نظر می‌رسد شناسایی ترافیک‌های سنگینی که با هر فرکانسی در تعدادی از کلاسترهای فیس‌بوک پایدار بمانند، چالش‌برانگیز است. علاوه بر این، حتی برای مقیاس‌های زمانی و سطوح تجمیعی که این امر ممکن است در آن‌ها میسر باشد (مانلاً: جریان‌های در سطح رک در بازه‌های ۱۰۰-میلی‌ثانیه یا بزرگتر)، مشخص نیست که مزیت بزرگی به دست آید، چرا که ترافیک‌های سنگین اغلب برای بخش عمده‌ای از دوره، به طور خاص سنگین نیستند. کارهای قبلی پیشنهاد کرده‌اند که طرح‌های مهندسی ترافیک می‌توانند مؤثر باشند اگر ٪۳۵ از ترافیک قابل پیش‌بینی باشد [۱۴]؛ تنها ترافیک‌های سنگین در سطح رک به این سطح از قابلیت پیش‌بینی هم برای سرورهای وب و هم برای سرورهای کش می‌رسند. این وضعیت تا حدودی غیرشهودی نتیجه ترکیبی از **توازن بار مؤثر** (که به معنای تفاوت اندک در اندازه بین یک ترافیک سنگین و جریان میانه است) و پهنای باند بلندمدت نسبتاً پایین بیشتر جریان‌هاست، به این معنی که حتی جریان‌های سنگین نیز می‌توانند به صورت داخلی ناگهانی (bursty)باشند.

## ۶ .سوئیچینگ

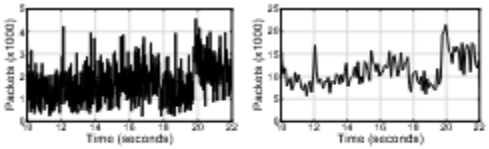
در نهایت، ما جنبه‌هایی از ترافیک را بررسی می‌کنیم که مستقیماً بر روی طراحی سوئیچ‌های بالای قفسه (top-of-rack) تأثیر می‌گذارند. به طور خاص، ما اندازه و فرآیندهای ورود بسته‌ها، و تعداد مقصدهای همزمان برای هر میزبان نهایی مشخص را در نظر می‌گیریم. علاوه بر این، ما تأثیر ناگهانی بودن (burstiness) در مقیاس‌های زمانی کوتاه و تأثیر آن بر بافرینگ سوئیچ را بررسی می‌کنیم.

### ۶.۱ ویژگی‌های به ازای هر بسته

شکل ۱۲ توزیع اندازه‌های بسته را برای هر یک از چهار نوع میزبان نشان می‌دهد. به طور کلی، اندازه میانه بسته تقریباً ۲۵۰ بایت است، اما این مقدار به طور قابل توجهی توسط ترافیک هدوپ انحراف دارد. ترافیک هدوپ دووجهی است: تقریباً تمام بسته‌ها یا به طول MTU (۱۵۰۰ بایت برای سرورهایی که ما مطالعه می‌کنیم) یاTCP ACK ها هستند. بسته‌ها برای سایر خدمات توزیع بسیار گسترده‌تری دارند، اما اندازه میانه بسته برای همه آن‌ها به طور قابل توجهی کمتر از ۲۰۰ بایت است، و تنها ۵- ٪۱۰ از بسته‌ها به طور کامل از MTU استفاده می‌کنند.




شکل ۱۲: توزیع اندازه بسته




شکل ۱۳: ترافیک هدوپ در مقیاس‌های ۱۵ و ۱۰۰ میلی‌ثانیه "روشن/خاموش" نیست.

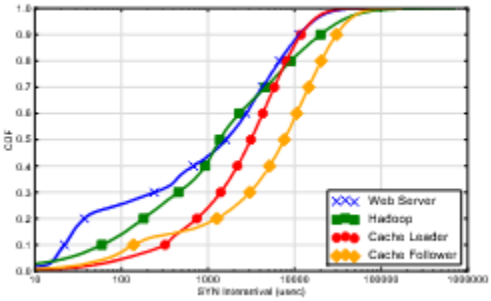
به این ترتیب، در حالی که استفاده از لینک پایین است، نرخ بسته هنوز بالاست. برای مثال، یک سرور کش با ٪۱۰ استفاده از لینک و اندازه میانه بسته تقریباً ۱۷۵ بایت، ٪۸۵ از نرخ بسته یک لینک کاملاً استفاده‌شده که بسته‌های با اندازه MTU ارسال می‌کند، را تولید می‌کند. در نتیجه، هر عملیات به ازای هر بسته) مثلاً، کپسوله‌سازی (VLAN ممکن است به گونه‌ای تحت فشار قرار گیرد که نرخ استفاده خالص از لینک در نگاه اول نشان ندهد.

### ۶.۲ الگوهای ورود

بنسون و همکاران مشاهده می‌کنند که ورود بسته‌ها الگوی **روشن/خاموش (on/off)** را در سطح میزبان نهایی [۱۲، ۱۳] نشان می‌دهد. میزبان‌ها در مرکز داده فیس‌بوک این رفتار را نشان نمی‌دهند، حتی در داخل کلاسترهای هدوپ. شکل ۱۳ یک سری زمانی از ترافیک ارسال شده توسط یک میزبان هدوپ) که به یک پورت RSW می‌رسد (

را که در فواصل ۱۵ و ۱۰۰ میلی‌ثانیه‌ای تقسیم‌بندی شده است، نشان می‌دهد (مراجعه کنید به نمودارهای مشابه بنسون و همکاران [۱۳، شکل ۵] و [۱۲، شکل ۶]). اگر ترافیک را بر اساس هر میزبان مقصد در نظر بگیریم، رفتار روشن/خاموش دوباره ظاهر می‌شود (که نشان داده نشده است)، و این نشان می‌دهد که ناپدید شدن آن ممکن است به دلیل تعداد زیادی از مقصدهای همزمان باشد.

شکل ۱۴ نمودار CDF زمان‌های بین‌ورود بین جریان‌های خروجی TCP را در هر یک از چهار نوع سروری که ما مطالعه می‌کنیم، ترسیم می‌کند. در حالی که مقدار قابل توجهی از ترافیک از طریق **اتصالات پویش‌شده با عمر طولانی** مسیریابی می‌شود، همانطور که در مورد ترافیک درخواست-پاسخ بین سرورهای وب و فالورهای کش صادق است، جریان‌های زودگذر نیز وجود دارند. زمان‌های بین‌ورود برای جریان‌های ناشی از هر چهار کلاس میزبان کوتاه‌تر از آن‌هایی است که در ادبیات علمی گزارش شده است [۲۶، شکل ۱۱]، اما با درجات متفاوت. گره‌های هدوپ و سرورهای وب افزایشی در حدود یک مرتبه بزرگی در شدت جریان نسبت به گزارش‌های قبلی نشان می‌دهند—که احتمالاً حداقل بخشی از آن به دلیل افزایش ۱۰ برابری در نرخ لینک است—با زمان‌های بین‌ورود میانه تقریباً ۲ میلی‌ثانیه (یعنی، بیش از ۵۰۰ جریان در ثانیه). شاید به دلیل **پویش اتصالی** (که ورود درخواست‌های کاربر خارجی را از نرخ ورود جریان داخلی جدا می‌کند)، توزیع زمان‌های بین‌ورود برای جریان‌ها در هر دو نوع گره کش مشابه و طولانی‌تر است: لیدرهای کش نرخ ورود کمی بالاتری نسبت به فالورها دارند، با زمان‌های بین‌ورود میانه به ترتیب ۳ و ۸ میلی‌ثانیه.

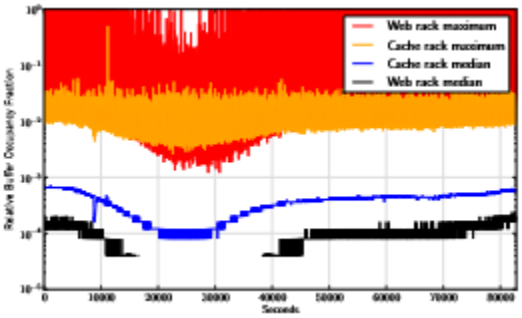



شکل ۱۴: زمان بین ورود جریان (بسته SYN)

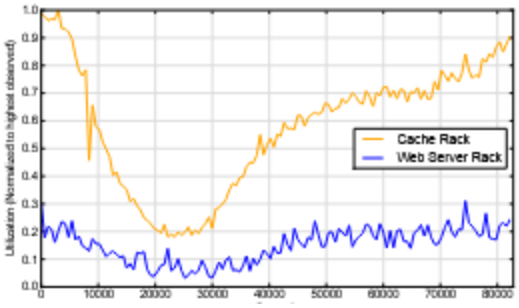
### ۶.۳ استفاده از بافر

ترکیبی از نبود ترافیک "روشن/خاموش"، شدت جریان بالا و جریان‌های ناگهانی فردی، پتانسیل افزایش استفاده از بافر و **سرریز (overruns)** را نشان می‌دهد. علیرغم استفاده پایین از لینک به طور متوسط، ترافیک ناگهانی می‌تواند به نرخ از دست دادن غیرقابل قبول منجر شود. کارهای اخیر در فیس‌بوک به توسعه پلتفرم‌های سوئیچینگ داخلی [۳۵] منجر شده است که ما را قادر می‌سازد آمار استفاده از بافر را با دقت بالا جمع‌آوری کنیم. به طور خاص، ما میزان اشغال بافر را در یک دوره ۲۴ ساعته برای سوئیچ‌هایی که سرورهای وب و گره‌های کش را به هم متصل می‌کنند، با دقت ۱۰-میکروثانیه جمع‌آوری می‌کنیم. شکل ۱۵الف مقادیر میانه و حداکثر را در هر ثانیه برای کل دوره ترسیم می‌کند که نسبت به اندازه بافر نرمال‌سازی شده‌اند. به عبارت دیگر، یک نقطه واحد برای سری میانه، نشان‌دهنده ۵۰مین صدک اشغال بافر در طول آن ثانیه (از بین ۱۰۰,۰۰۰ نمونه در هر ثانیه) است که بر اساس اندازه بافر نرمال‌سازی شده است. ما همچنین استفاده متوسط نرمال‌سازی‌شده از لینک (شکل ۱۵ب) و نرخ بسته‌های خروجی (شکل ۱۵ج) را در همان دوره ترسیم می‌کنیم که به ترتیب از طریق fbflow و شمارنده‌های SNMP به دست آمده‌اند.

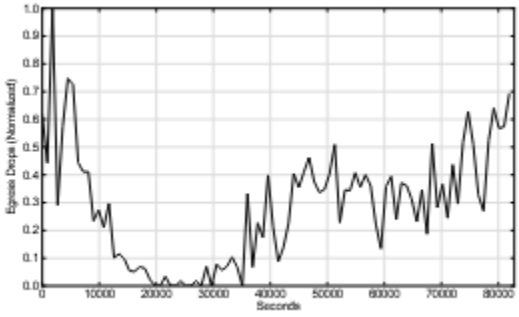
چند روند از نتایج ما آشکار است. اولین مورد این است که اشغال‌های بافر ثابت بی‌اهمیت نیستند و می‌توانند در مورد سرورهای وب کاملاً بالا باشند. حتی با وجود اینکه استفاده از لینک تقریباً در ۱٪ از مواقع پایین است، بیش از دو-سوم از بافر مشترک موجود در هر بازه ۱۰-میکروثانیه‌ای استفاده می‌شود. تغییرات شبانه‌روزی در اشغال‌های بافر، استفاده و نرخ از دست دادن بسته وجود دارد که همبستگی بین این معیارها را برجسته می‌کند. حتی با الگوی ترافیک شبانه‌روزی، حداکثر اشغال بافر در قفسه سرور وب برای تقریباً سه چهارم دوره ۲۴ ساعته به حد پیکربندی‌شده نزدیک می‌شود. در حالی که استفاده از لینک تقریباً در حالی که استفاده از لینک با اشغال بافر در داخل قفسه سرور وب مرتبط است، میزان استفاده (utilization) به تنهایی پیش‌بینی خوبی از نیازهای بافر در برنامه‌های مختلف نیست. به طور خاص، قفسه کش استفاده از لینک بالاتری دارد، اما استفاده از بافر و نرخ از دست دادن بسته (drop rates) بسیار پایین‌تری دارد (که نشان داده نشده است).




الف) اشغال بافر نرمال‌سازی شده، با دقت ۱۰ میکروثانیه




ب) استفاده از لینک، میانگین ۱۰-دقیقه‌ای




ج) بسته‌های از دست رفته خروجی از رک وب، میانگین ۱۵-دقیقه‌ای

شکل ۱۵: همبستگی اشغال بافر، استفاده از لینک و بسته‌های از دست رفته در قفسه‌های سرور وب و کش

این سطوح استفاده از بافر، علی‌رغم اندازه‌های نسبتاً کوچک بسته (بخش ۶.۱) رخ می‌دهند. همانطور که استفاده در آینده افزایش می‌یابد، ممکن است از طریق افزایش در تعداد جریان‌ها، در اندازه بسته‌ها، یا هر دو باشد. هر کدام از این موارد بر استفاده از بافر تأثیر خواهد گذاشت: بسته‌های بزرگتر با همان سطح از ناگهانی بودن (burstiness)، بافر بیشتری را مصرف خواهند کرد، در حالی که تعداد بیشتری از جریان‌ها منجر به شانس بیشتری برای ارسال همزمان بسته‌های ناگهانی توسط چندین جریان می‌شود. بنابراین، تنظیم دقیق بافر احتمالاً در آینده مهم خواهد بود.

### ۶.۴ جریان‌های همزمان

ما جریان‌های همزمان را به معنای وجود همزمان در یک بازه زمانی ۵-میلی‌ثانیه در نظر می‌گیریم (مراجعه کنید به پنجره ۵۰-میلی‌ثانیه که توسط علیزاده و همکاران [۸] هنگام اندازه‌گیری مرکز داده‌ای که با لینک‌های ۱-گیگابیت بر ثانیه متصل است، در نظر گرفته شده است). ما دریافتیم که سرورهای وب و میزبان‌های کش صدها تا هزاران اتصال همزمان دارند (در سطح ۵-تاپل)، در حالی که گره‌های هدوپ به طور متوسط تقریباً ۲۵ اتصال همزمان دارند—که با یافته‌های علیزاده و همکاران [۸، شکل ۵] مطابقت دارد. گفته می‌شود، سوئیچ‌ها به وضوح با اتصالات فردی نسبت به پورت‌های مقصد کمتر نگران هستند. اگر جریان‌ها را بر اساس گروه‌هایی که به یک پورت مقصد مشخص هدایت می‌شوند، گروه‌بندی کنیم، تعداد میزبان‌ها تنها کمی کاهش می‌یابد (حداکثر با یک فاکتور دو) و در مورد هدوپ اصلاً کاهش نمی‌یابد.

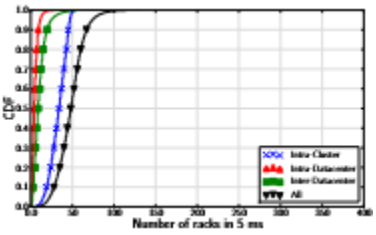
با توجه به نبود کلی ترافیک درون-رک، تقریباً تمام جریان‌ها یک پورت بالاسری را اشغال می‌کنند. از این رو، شاید در نظر گرفتن تعداد جریان‌هایی که یک رک مشخص با آن‌ها ارتباط برقرار می‌کند، مفیدتر باشد. شکل ۱۶ تعداد جریان‌های همزمان ارسال شده توسط یک میزبان واحد را در یک بازه ۵-دقیقه‌ای به کلاس‌های مختلف میزبان مقصد برای سه نوع میزبان مختلف نشان می‌دهد: فالور کش، لیدر کش و سرور وب. فالورهای کش با ۳۰۰-۲۲۵ رک مختلف ارتباط برقرار می‌کنند، در حالی که لیدرها با ۳۵۰-۱۷۵ ارتباط دارند. در بازه زمانی میانه، هر دو نوع گره کش با تقریباً ۲۵۰ رک دیگر ارتباط برقرار می‌کنند—مکان رک‌ها به طور چشمگیری متفاوت است. با این حال، سرورهای وب با ۱۲۵-۱۰ رک در حالت میانه ارتباط برقرار می‌کنند.

برخی از طراحی‌های سوئیچ پیشنهادی [۲۵، ۳۰] از تکنولوژی‌های متفاوتی برای جریان‌های بزرگ استفاده می‌کنند. از آنجا که ما تمرکز خود را به ترافیک‌های سنگین در سطح رک محدود می‌کنیم، که بخش عمده ترافیک را تشکیل می‌دهند، تعداد میانه رک‌های ترافیک سنگین ۶ تا ۸ برای سرورهای وب و لیدرهای کش است که دارای یک فاکتور مؤثر ۲۰ تا ۳۰ است، در حالی که فالور کش ۲۹ رک ترافیک سنگین در حالت میانه و تا ۵۰ رک در دم توزیع دارد. به دلیل تفاوت در محلی‌گرایی، سرورهای وب و فالورهای کش دارای رک‌های ترافیک سنگین درون-رکی بسیار کمی هستند، در حالی که لیدر کش الگوی برعکس را نشان می‌دهد. حتی با در نظر گرفتن ترافیک‌های سنگین در سطح رک، تعداد مقصدهای همزمان به طور قابل توجهی بزرگتر از آن است که توسط علیزاده و همکاران [۸] گزارش شده است. علاوه بر این، غیرقابل پیش‌بینی بودن نسبی ترافیک‌های سنگین ما نشان می‌دهد که رویکردهای هیبریدی مبتنی بر مدار، برای کلاسترهای فرانت‌اند، حداقل، ممکن است برای استفاده چالش‌برانگیز باشند.

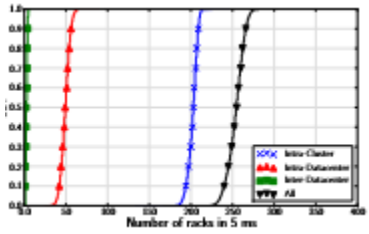
## ۷ .نتیجه‌گیری

شبکه مرکز داده فیس‌بوک از مجموعه‌ای از خدمات متمایز پشتیبانی می‌کند که الگوهای ترافیکی متفاوتی را از خود نشان می‌دهند. ما دریافتیم که چندین مورد به طور قابل توجهی از خدماتی که در ادبیات علمی در نظر گرفته شده‌اند، انحراف دارند. برنامه‌های کاربردی متفاوت، همراه با مقیاس (صدها هزار گره) و سرعت (لینک‌های لبه ۱۰-گیگابیت بر ثانیه) شبکه مرکز داده فیس‌بوک، منجر به بارهای کاری می‌شوند که از چند جهت با اکثر مجموعه‌داده‌های منتشر شده قبلی در تضاد هستند.

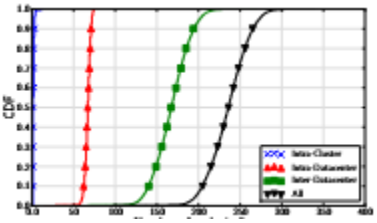
محدودیت‌های فضا ما را از ارائه یک گزارش جامع باز می‌دارد؛ ما ویژگی‌هایی را توصیف می‌کنیم که ممکن است پیامدهایی برای توپولوژی، مهندسی ترافیک، و طراحی سوئیچ بالای قفسه داشته باشند.



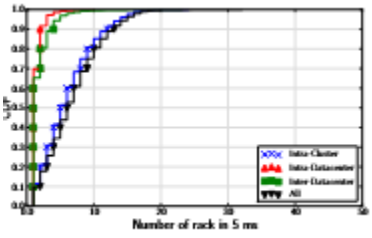

الف) سرور وب



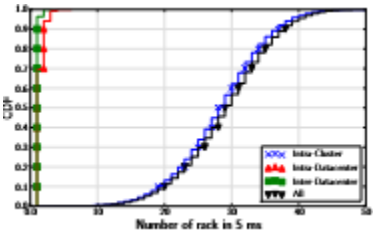

ب) فالور کش



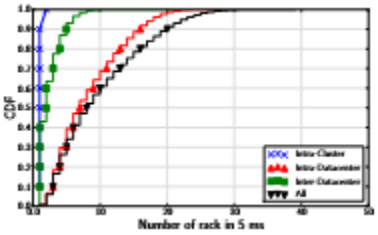

ج) لیدر کش




الف) سرور وب




ب) فالور کش




ج) لیدر کش

متدولوژی ما چند محدودیت را بر دامنه این مطالعه تحمیل می‌کند. استفاده از میزبان‌های نهایی برای ضبط و زمان‌بندی بسته‌ها، تغییراتی مبتنی بر زمان‌بندی (scheduler-based) را بر دقت مهر زمانی (timestamp)وارد می‌کند. علاوه بر این، ما می‌توانیم تنها ترافیک را از تعداد کمی از میزبان‌ها در یک زمان، بدون ریسک از دست دادن بسته‌ها در جمع‌آوری، ثبت کنیم. این محدودیت‌ها در مجموع ما را از ارزیابی اثراتی مانند **اینکست (incast)** یا **مایکروبرست (microbursts)**که به عنوان عوامل مؤثر در عملکرد ضعیف برنامه [۲۴] شناخته می‌شوند، باز می‌دارد. علاوه بر این، جمع‌آوری بسته‌ها به ازای هر میزبان، به ناچار جنبه حکایتی و موردی دارد و به حضور یک میزبان جمع‌آوری استفاده‌نشده در همان قفسه هدف وابسته است. در حالی که **Fbflow**در سطح کل مرکز داده مستقر شده است، حجم محض داده‌های اندازه‌گیری که فراهم می‌کند، چالش دیگری را به وجود می‌آورد—به طور خاص، یک چالش در پردازش و نگهداری داده‌ها—که **دقت (resolution)** عملکرد آن را محدود می‌کند. بنابراین، ما نظارت و تحلیل مؤثر شبکه را یک مشکل مداوم و در حال تکامل می‌دانیم.

## سپاسگزاری‌ها(Acknowledgements)


این کار تا حدی توسط **بنیاد ملی علوم** از طریق کمک‌های مالی **CNS-۱۳۱۴۹۲۱**و **CSR-1018808**پشتیبانی می‌شود. ما مدیون **تئو بنسون، نیک مک‌کوون، رمزی آرپاچی–داسو** که راهنمای ما بود، **سریکانت کاندولا**، و داوران ناشناس برای نظرات و پیشنهاداتشان در مورد پیش‌نویس‌های اولیه این دست‌نوشته هستیم .**پتر لاپوخوف، میخال بورگر، ساتیا نارایانان، اوری چینگ** و **وینسنت لیو** دیدگاه‌های ارزشمندی را در مورد کارکرد درونی خدمات مختلف فیس‌بوک ارائه دادند. در نهایت، و مهم‌تر از همه، **عمر بالدونادو** این همکاری را که این مطالعه را ممکن ساخت، تسریع و تسهیل کرد.

## ۸. منابع


[1] An open network operating system. http://onosproject.org. [2] Scribe (archived). https://github.com/facebookarchive/scribe. [3] L. Abraham, J. Allen, O. Barykin, V. Borkar, B. Chopra, C. Gerea, D. Merl, J. Metzler, D. Reiss, S. Subramanian, J. L. Wiener, and O. Zed. Scuba: Diving into data at Facebook. Proc. VLDB Endow., 6(11):1057–1067, Aug. 2013. [4] M. Al-Fares, A. Loukissa, and A. Vahdat. A scalable, commodity, data center network architecture. In Proc. ACM SIGCOMM, Aug. 2008. [5] M. Al-Fares, S. Radhakrishnan, B. Raghavan, N. Huang, and A. Vahdat. Hedera: Dynamic flow scheduling for data center networks. In Proc. USENIX NSDI, Apr. 2010. [6] A. Alameelden, M. Martin, C. Mauer, K. Moore, X. Min, M. Hill, D. Wood, and D. Sorin. Simulating a $2M commercial server on a $2K PC. IEEE Computer, 36(2):50–57, Feb. 2003. [7] M. Alizadeh, T. Edsall, S. Dharmapurikar, R. Vaidyanathan, K. Chu, A. Fingerhut, V. T. Lam, F. Matus, R. Pan, N. Yadav, and G. Varghese. Conga: Distributed congestion-aware load balancing for datacenters. In Proc. ACM SIGCOMM, Aug. 2014. [8] M. Alizadeh, A. Greenberg, D. A. Maltz, J. Padhye, P. Patel, B. Prabhakar, S. Sengupta, and M. Sridharan. Data center TCP (DCTCP). In Proc. ACM SIGCOMM, Aug. 2010. [9] A. Andreyev. Introducing data center fabric, the next-generation Facebook data center network.
https://code.facebook.com/posts/360346274145
۹۴۳, ۲۰۱۴. [۱۰] B. Atikoglu, Y. Xu, E. Frachtenberg, S. Jiang, and M. Paleczny. Workload analysis of a large-scale key-value store. In Proc. ACM SIGMETRICS/Performance, June 2012. [11] L. A. Barroso, J. Clidaras, and U. Holzle. The Datacenter as a Computer:An Introduction to the Design of Warehouse-Scale Machines. Morgan & Claypool, 2nd edition, 2013. [12] T. Benson, A. Akella, and D. A. Maltz. Network traffic characteristics of data centers in the wild. In Proc. ACM IMC, 2010. [13] T. Benson, A. Anand, A. Akella, and M. Zhang. Understanding data center traffic characteristics. In Proc. ACM SIGCOMM WREN, Aug. 2009. [14] T. Benson, A. Anand, A. Akella, and M. Zhang. MicroTE: Fine-grained traffic engineering for data centers. In Proc. ACM CoNEXT, Dec. 2011. [15] N. Bronson, Z. Amsden, G. Cabrera, P. Chakka, P. Dimov, H. Ding, J. Ferris, A. Giardullo, S. Kulkarmi, H. Li, M. Marchukov, D. Petrov, L. Puzar, Y. J. Song, and V. Venkataramani. TAO: Facebook's distributed data store for the social graph. In Proc. USENIX ATC, June 2013. [16] M. Chowdhury, M. Zaharia, J. Ma, M. I. Jordan, and J. Stoica. Managing data transfers in computer clusters with orchestra. In Proceedings of the ACM SIGCOMM 2011 Conference, SIGCOMM '11, pages 98–109, New York, NY, USA, 2011. ACM. [17] G. Delimitrou, S. Sankar, A. Kansal, and C. Kozyrakis. ECHO: Recreating network traffic maps for datacenters with tens of thousands of servers. In Proc. IEEE International Symposium on Workload Characterization, Nov. 2012. [18] D. Ersoz, M. S. Yousif, and C. R. Das. Characterizing network traffic in a cluster based, multi-tier data center. In Proc. IEEE International Conference on Distributed Computing Systems, June 2007. [19] N. Farrington and A. Andreyev. Facebook's data center network architecture. In Proc. IEEE Optical Interconnects, May 2013. [20] N. Farrington, G. Porter, S. Radhakrishnan, H. Bazzaz, V. Subramanya, Y. Fainman, G. Papen, and A. Vahdat. Helios: A hybrid electrical/optical switch architecture for modular data centers. In Proc. ACM SIGCOMM, Aug. 2010. [21] A. Greenberg, J. R. Hamilton, N. Jain, S. Kandula, C. Kim, P. Lahiri, D. A. Maltz, P. Patel, and S. Sengupta. VL2: A scalable and flexible data center network. In Proc. ACM SIGCOMM, Aug. 2009. [22] N. Gude, L. Koponen, J. Pettit, B. Pfaff, M. Casado, N. McKeown, and S. Shenker. NOX: Towards an operating system for networks. SIGCOMM CCR, 38(3), July 2008. [23] C. Guo, G. Lu, D. Li, H. Wu, X. Zhang, Y. Shi, C. Tian, Y. Zhang, and S. Lu. BCube: A high performance, server-centric network architecture for modular data centers. In Proc. ACM SIGCOMM, Aug. 2009. [24] V. Jalaparti, P. Bux, S. Kandula, I. Menache, M. Rybalkin, and C. Yan. Speeding up distributed request-response workflows. In Proceedings of the ACM SIGCOMM 2013 Conference on SIGCOMM, SIGCOMM '13, pages 219–230, New York, NY, USA, 2013. ACM. [25] S. Kandula, S. Pathaye, and P. Bahl. Flyways to de-congest data center networks. In Proc. ACM HotNets, Oct. 2009. [26] S. Kandula, S. Sengupta, A. Greenberg, P. Patel, and R. Chaiken. The nature of data center traffic: Measurements & analysiss. In Proc. ACM IMC, Nov. 2009. [27] R. Kapoor, A. C. Snoeren, G. M. Voelker, and G. Porter. Bullet trains:

Zheng. Mirror mirror on the ceiling: Flexible wireless links for data centers. In Proc. ACM SIGCOMM, Aug. 2012.

A study of NIC burst behavior at microsecond timescales. In Proc. ACM CoNEXT, Dec. 2013. [28] T. Koponen, M. Casado, N. Gude, J. Stribling, L. Poutieryski, M. Zhu, R. Ramanathan, Y. Iovata, H. Irouta, T. Hama, and S. Shenker. Onix: A distributed control platform for large-scale production networks. In Proc. USENIX OSDI, 2010. [29] A. Likhtorov, R. Nishtala, R. McElroy, H. Fugal, A. Grynenko, and V. Venkataramani. Introducing microuter: A memcached protocol router for scaling memcached deployments. https://code.facebook.com/posts/296442737213493, Sept. ۲۰۱۴. [۳۰] H. Liu, F. Lu, A. Forencich, R. Kapoor, M. Tewari, G. M. Voelker, G. Papen, A. C. Snoeren, and G. Porter. Circuit switching under the radar with REACToR. In Proc. USENIX NSDI, Apr. 2014. [31] R. Macky. Banking timeline: Scaling up to hold your life story. https://www.facebook.com/note.php?note_id=۱۰۱۵۰۴۶۸۲۵۵۶۲۸۹۲۰, Jan. ۲۰۱۲. [۳۲] B. Pfaff, J. Pettit, T. Koponen, K. Amidou, M. Casado, and S. Shenker. Extending networking into the virtualization layer. In Proc. ACM HotNets, 2009. [33] L. Popa, S. Ratnasamy, G. Iannaccone, A. Krishnamurthy, and I. Stoica. A cost comparison of datacenter network architectures. In Proc. ACM CoNEXT, Dec. 2010. [34] R. Sherwood, G. Gibb, K.-K. Yap, G. Appenzeller, M. Casado, N. McKeown, and G. Parulkar. Can the production network be the testbed? In Proc. USENIX OSDI, 2010. [35] A. Simpkins. Facebook open switching system (fboss) and wedge in the open. https://code.facebook.com/posts/843620439027582/ facebook-open-switching-system-fboss-and-wedge-in-the-open/, 2015. [36] A. Singla, C.-Y. Hong, L. Popa, and P. B. Godfrey. Jellyfish: Networking data centers randomly. In Proc. USENIX NSDI, Apr. 2012. [37] D. Sammermann and A. Friadel. Introducing Proxygen, Facebook's C++ HTTP framework. https://code.facebook.com/posts/1503205539947302, 2014. [38] A. Thusoo, J. S. Sarma, N. Jain, Z. Shao, P. Chakka, N. Zhang, S. Antony, H. Liu, and R. Murthy. Hive – a petabyte scale data warehouse using Hadoop. In Proc. IEEE ICDE, Mar. 2010. [39] G. Wang, D. G. Andersen, M. Kaminsky, K. Papagiannaki, T. S. E. Ng, M. Kozuch, and M. Ryan. cThrough: Part-time optics in data centers. In Proc. ACM SIGCOMM, Aug. 2010. [40] X. Zhou, Z. Zhang, Y. Zhu, Y. Li, S. Kumar, A. Vahdat, B. Y. Zheng, and H.