NoSQL

پایگاه داده‌های غیر رابطه‌ای

mmoradi.uni@gmail.com

Sensor data from a cross-country flight



Picture credit: HP

20 TB	× 2	× 6	× 28,537	× 365
20 terabytes of information per engine every hour	twin-engine Boeing 737	six-hour, cross-country flight from New York to Los Angeles	# of commercial flights in the sky in the United States on any given day.	days in a year

= 2,499,841,200 TB

The FOUR V's of Big Data

From traffic patterns and music downloads to web history and medical records, data is recorded, stored, and analyzed to enable the technology and services that the world relies on every day. But what exactly is big data, and how can these massive amounts of data be used?

As a leader in the sector, IBM data scientists break big data into four dimensions: **Volume, Velocity, Variety and Veracity**

Depending on the industry and organization, big data encompasses information from multiple internal and external sources such as transactions, social media, enterprise content, sensors and mobile devices. Companies can leverage data to adapt their products and services to better meet customer needs, optimize operations and infrastructure, and find new sources of revenue.

By 2015

4.4 MILLION IT JOBS

will be created globally to support big data, with 1.9 million in the United States



Volume

SCALE OF DATA

حجم زیاد

40 ZETTABYTES

[43 TRILLION GIGABYTES]

of data will be created by 2020, an increase of 300 times from 2005



It's estimated that

2.5 QUINTILLION BYTES

[2.3 TRILLION GIGABYTES]

of data are created each day



6 BILLION PEOPLE

have cell phones



WORLD POPULATION: 7 BILLION



Most companies in the U.S. have at least

100 TERABYTES

[100,000 GIGABYTES]

of data stored

Variety

DIFFERENT FORMS OF DATA

انواع داده‌های متنی، مالتی مدیا و ..

As of 2011, the global size of data in healthcare was estimated to be

150 EXABYTES

[161 BILLION GIGABYTES]



30 BILLION PIECES OF CONTENT

are shared on Facebook every month



By 2014, it's anticipated there will be

420 MILLION WEARABLE, WIRELESS HEALTH MONITORS



4 BILLION+ HOURS OF VIDEO

are watched on YouTube each month





400 MILLION TWEETS

are sent per day by about 200 million monthly active users

Velocity

ANALYSIS OF STREAMING DATA

سرعت تولید زیاد

The New York Stock Exchange captures

1 TB OF TRADE INFORMATION

during each trading session



Modern cars have close to

100 SENSORS

that monitor items such as fuel level and tire pressure



By 2016, it is projected there will be

18.9 BILLION NETWORK CONNECTIONS

– almost 2.5 connections per person on earth



Veracity

UNCERTAINTY OF DATA

داده‌های ناکامل، عدم قطعیت و ...

1 IN 3 BUSINESS LEADERS

don't trust the information they use to make decisions





in one survey were unsure of how much of their data was inaccurate

Poor data quality costs the US economy around

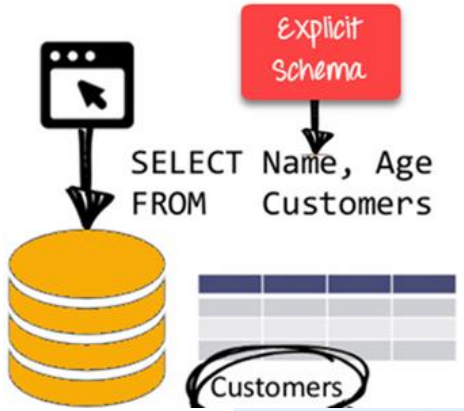
$3.1 TRILLION A YEAR



Sources: McKinsey Global Institute, Twitter, Cisco, Gartner, EMC, SAS, IBM, MEPTEC, QAS

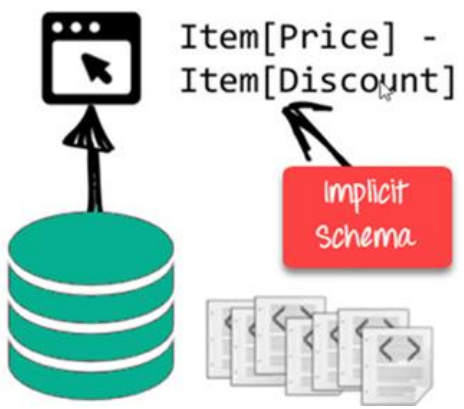
IBM

RDBMS:

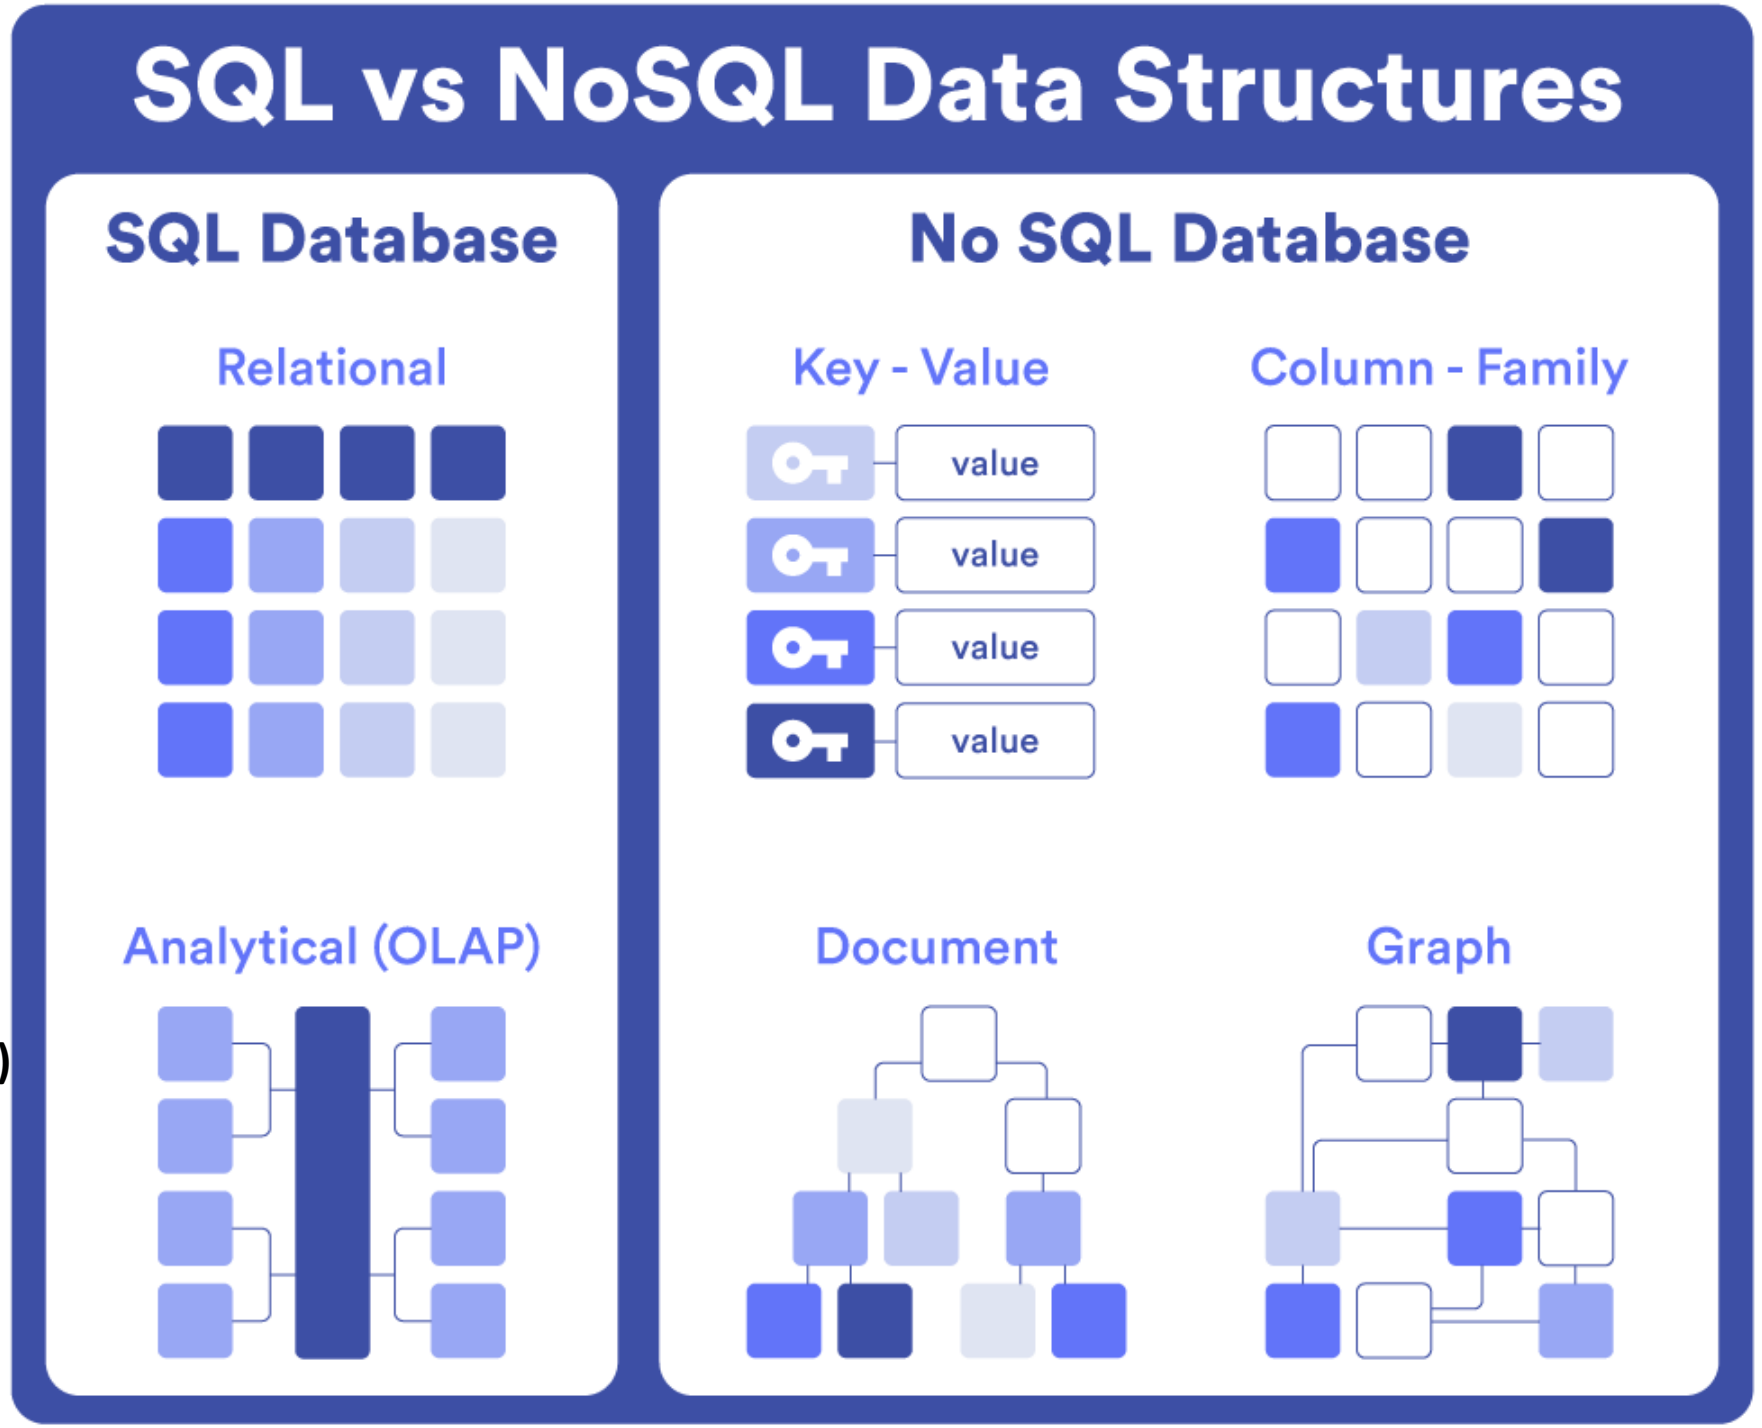




NoSQL DB:



SQL vs NoSQL Data Structures

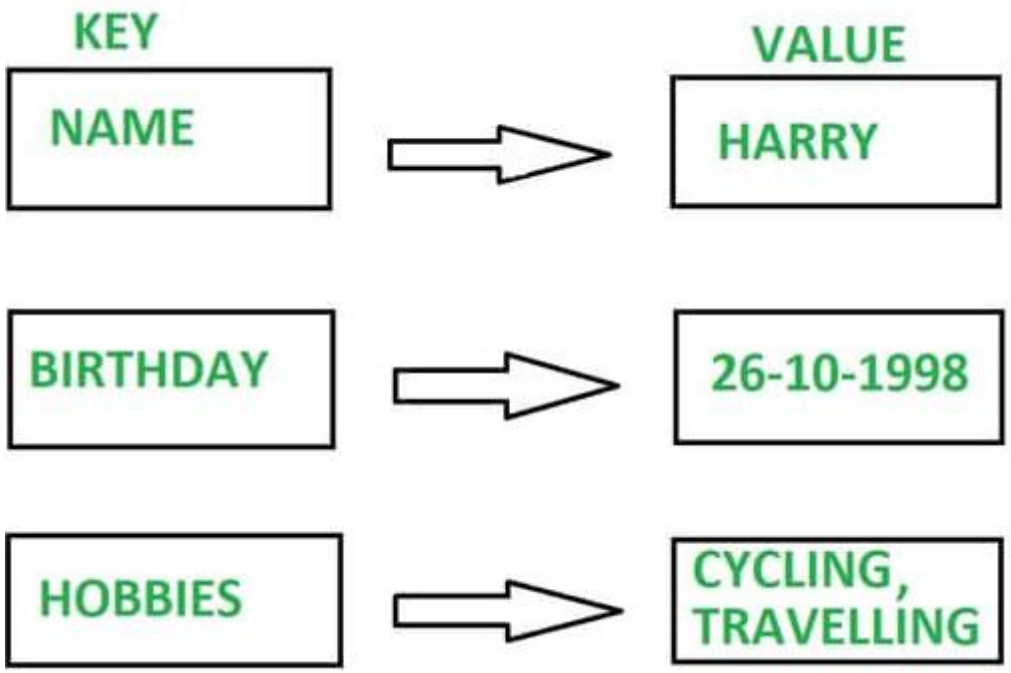


OnLine Transactional Processing (OLTP)
اتصال به پایگاه داده، نوشتن کوئری و ...

Dataware house/ OnLine Analytical Processing (OLAP)
برای تصمیم‌سازی و ارائه گزارش مدیریتی بدون ذکر جزئیات- مثلا فروش ۱۰ ساله محصول

استخراج دانش با استفاده از داده کاوی و اجرای الگوریتم های یادگیری ماشین

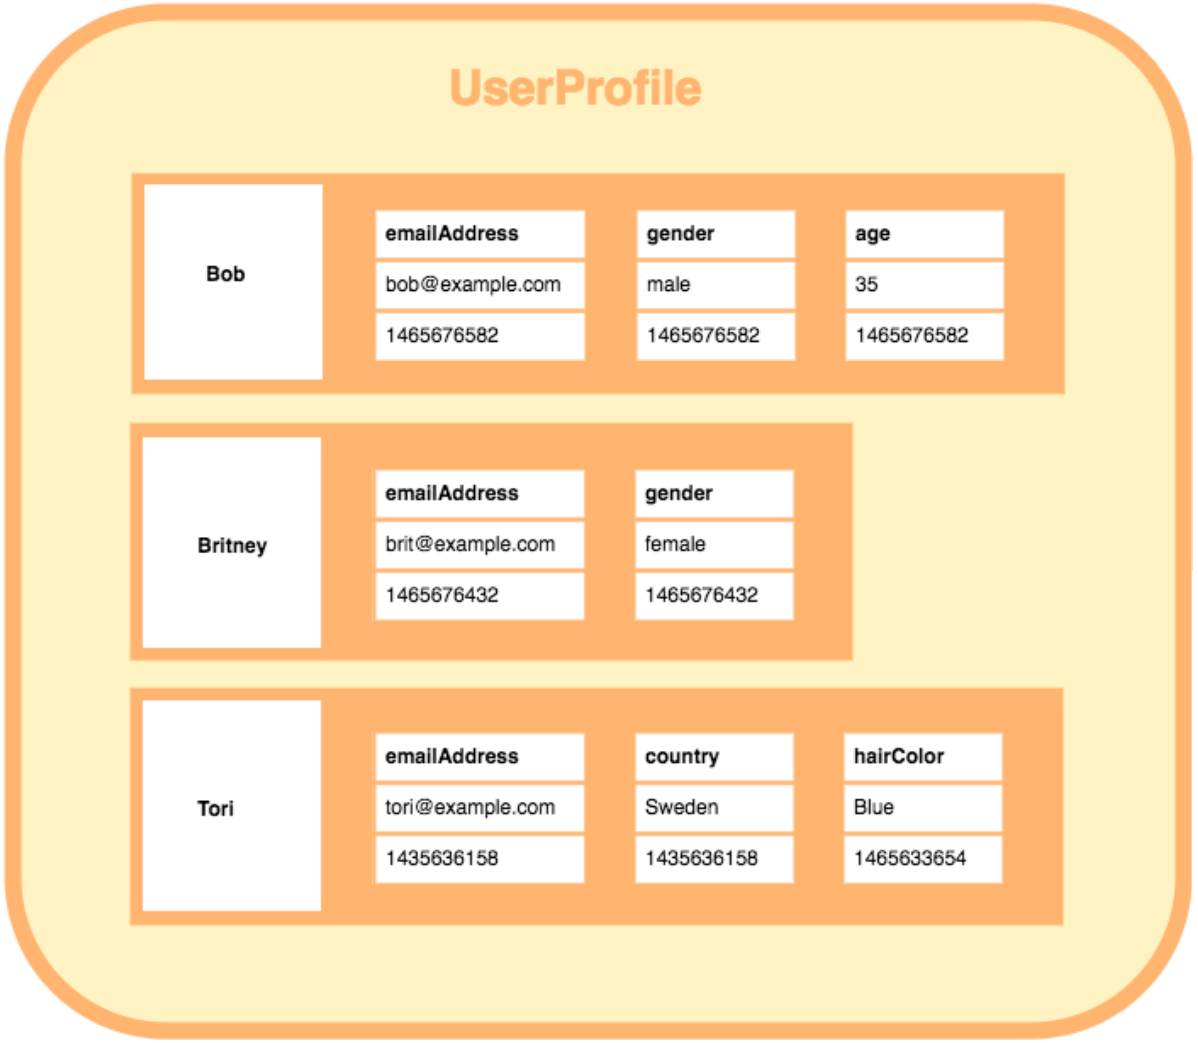
پایگاه داده Key-value

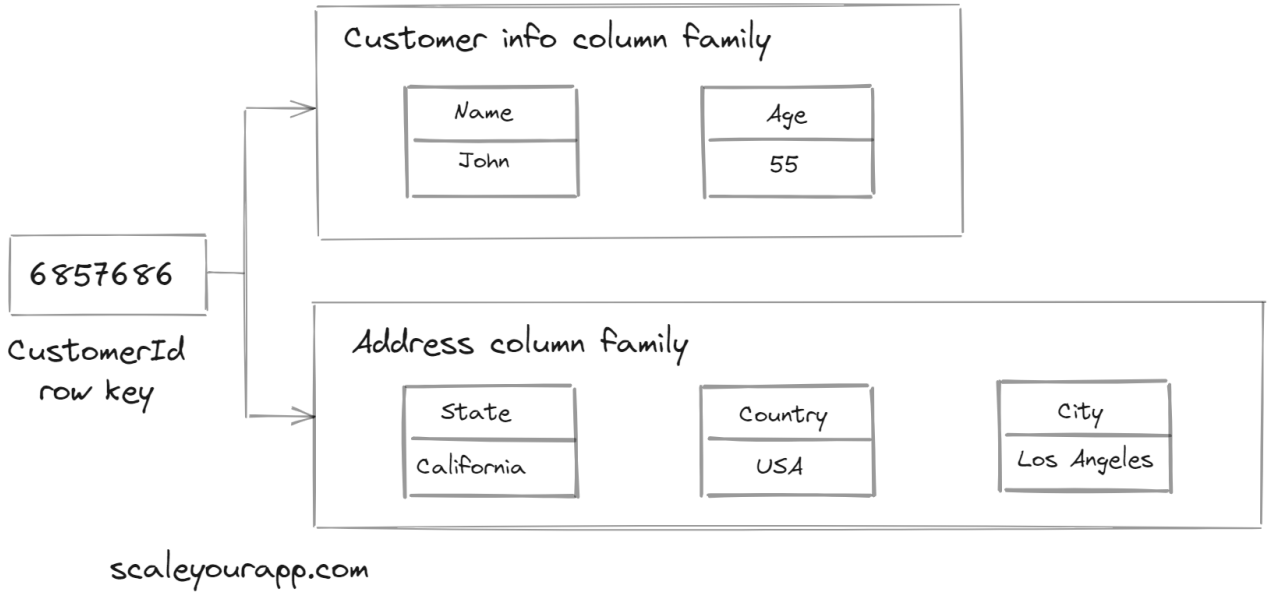


پایگاه داده های Redis, DynamoDB
کاربرد: کش، داده‌های Session

پایگاه داده Column family

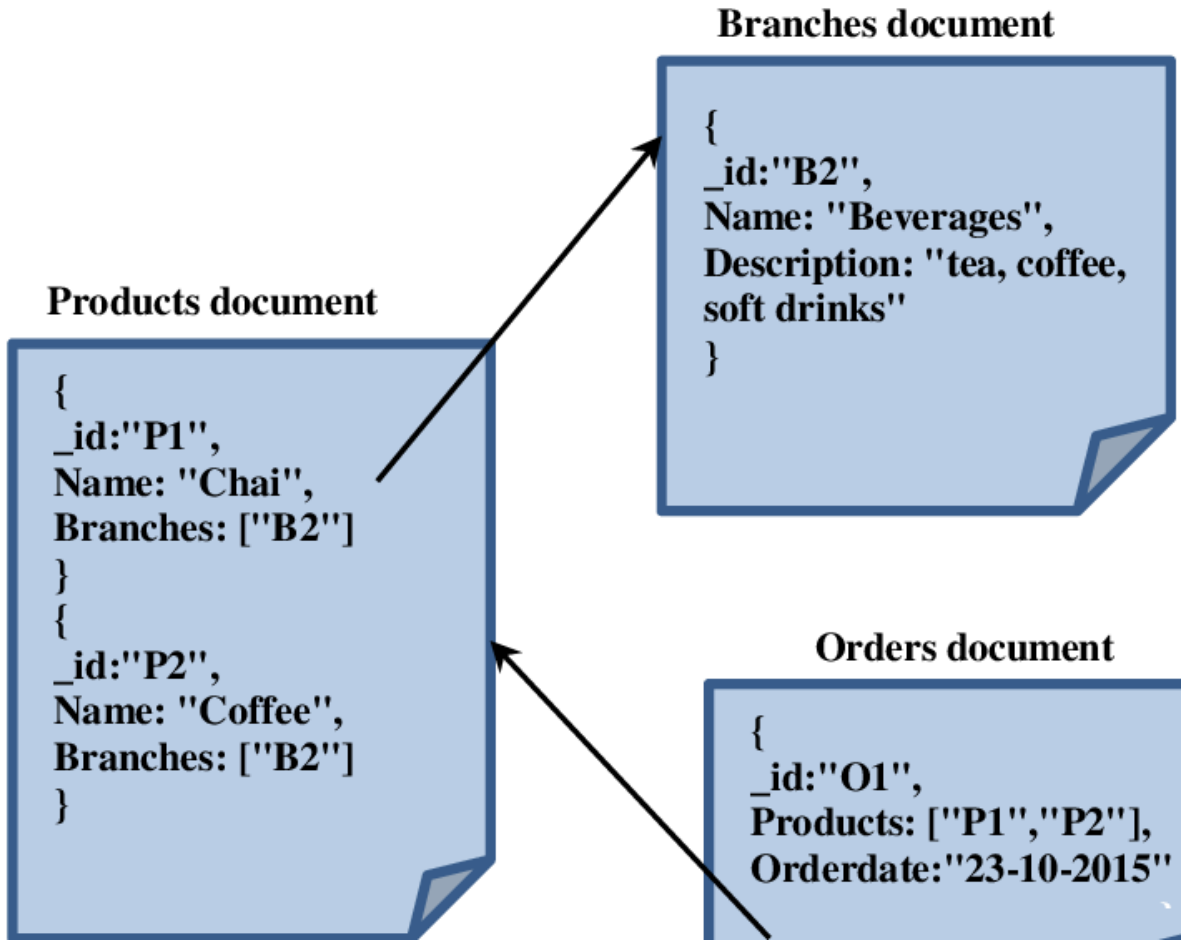
پایگاه داده های Cassandra, HBase
کاربرد: تحلیل‌های حجیم، IoT





Column-family data storage

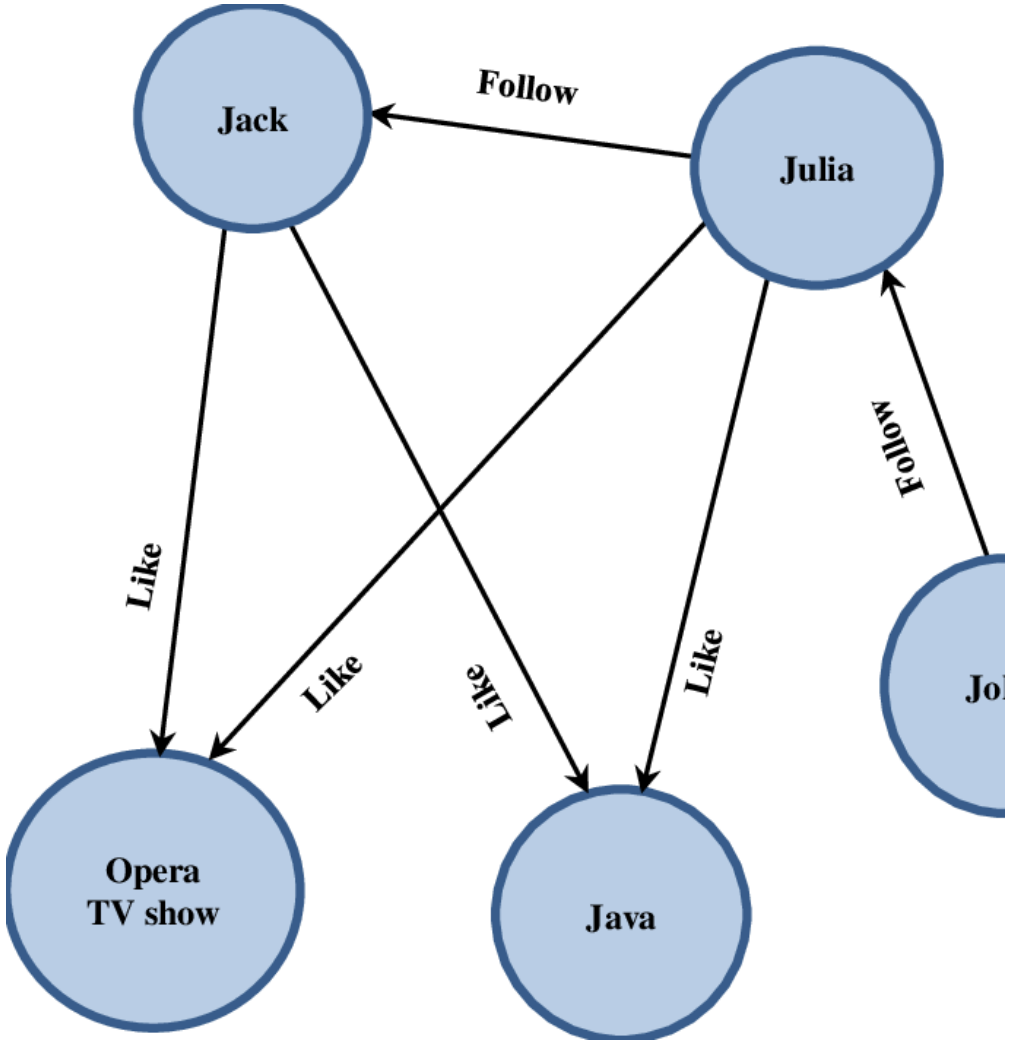
پایگاه داده Document



پایگاه داده های MongoDB, CouchDB

کاربرد: اپلیکیشن‌های وب و ذخیره JSON

پایگاه داده Graph



پایگاه داده های Neo4j

کاربرد: شبکه‌های اجتماعی و روابط پیچیده

مقایسه از نظر ساختار داده

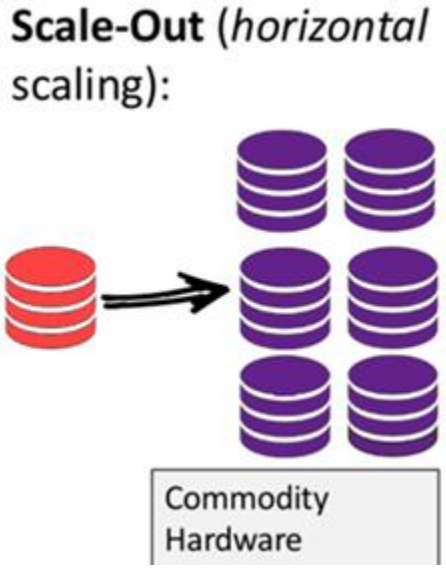
مورد	رابطه‌ای	غیررابطه‌ای
الگوی داده	جدول‌محور (سطر و ستون)	انعطاف‌پذیر Document، Key-Value، Graph، Column-based
نوع داده	از پیش تعریف شده	پویا و بدون نیاز به schema ثابت مثل داده‌های متنی، صوتی، ویدئو، بلاگ، توئیت، جریان‌های کلیک، لاگ فایل داده‌های حسگر و ...
روابط بین داده	مبتنی بر کلیدهای خارجی و joinها	اغلب بدون رابطه یا با روابط ساده‌تر

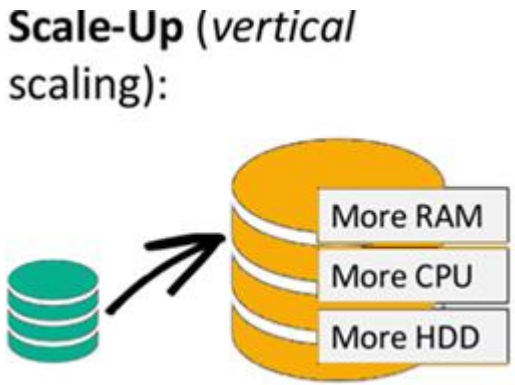
مقایسه از نظر زبان و روش دسترسی

مورد	رابطه‌ای	غیررابطه‌ای
زبان پرس‌وجو	SQLاستاندارد	هر سیستم زبان خاص خود را دارد مثلا json-based query در MongoDB
ساختار پرس‌وجو	پیچیده و قدرتمند JOIN, GROUP BY, ...	ساده‌تر، بهینه برای خواندن/نوشتن سریع

مقایسه از نظر مقیاس‌پذیری و عملکرد

مورد	رابطه‌ای	غیررابطه‌ای
مقیاس‌پذیری	عمودی (افزایش قدرت یک سرور) در این روش شما سرورتون رو قوی‌تر می‌کنید.	افقی (افزودن سرورهای بیشتر) در این روش شما داده رو تکه تکه می‌کنید و هر تکه رو روی یه سرور نگهداری می‌کنید.
عملکرد در داده‌های حجیم	کندتر در مقایسه با NoSQL	مناسب برای داده‌های بسیار حجیم و توزیع‌شده
کارایی بر روی تراکنش‌ها	عالی به دلیل ACID	اغلب با اولویت سرعت





مقایسه از نظر یکپارچگی و سازگاری داده

مورد	رابطه‌ای	غیررابطه‌ای
تضمین صحت تراکنش	قوی ACID	بعضی از سیستم‌ها ضعیف‌تر، مبتنی بر Eventual Consistency
مناسب برای داده‌ی ساخت‌یافته	بسیار مناسب	مناسب برای داده‌های نیمه‌ساخت‌یافته و بدون ساختار

Eventual Consistency(سازگاری نهایی) یک مدل سازگاری داده در سیستم‌های توزیع‌شده است که در آن به‌روزرسانی‌های انجام‌شده روی داده‌ها ممکن است فوراً در تمام گره‌ها (سرورها) قابل مشاهده نباشند، اما پس از گذشت مدت زمانی، همه‌ی گره‌ها نهایتاً به یک وضعیت سازگار می‌رسند.

کاربردها و مثال‌هایی از پایگاه داده



Redis



MongoDB



MySQL

رابطه‌ای	غیررابطه‌ای
سیستم‌های مالی، بانکی	شبکه‌های اجتماعی و تحلیل رفتار کاربر
سامانه‌های مدیریتی (ERP، فروش، موجودی)	ذخیره‌سازی Big Data و Logها
هر جایی که روابط پیچیده‌ی داده مهم است	اپ‌های Real-time و Scaleبالا مثلاً چت، IoT



PostgreSQL



رابطه‌ای	غیررابطه‌ای
MySQL, PostgreSQL, SQL Server, Oracle	MongoDB (Document) ،Redis (Key-Value) ، Neo4j (Graph) ،Cassandra (Column-based)





Microsoft SQL Server

MongoDB



SAP®

facebook

Adobe®

Google

cisco

EA

ebay

PayPal

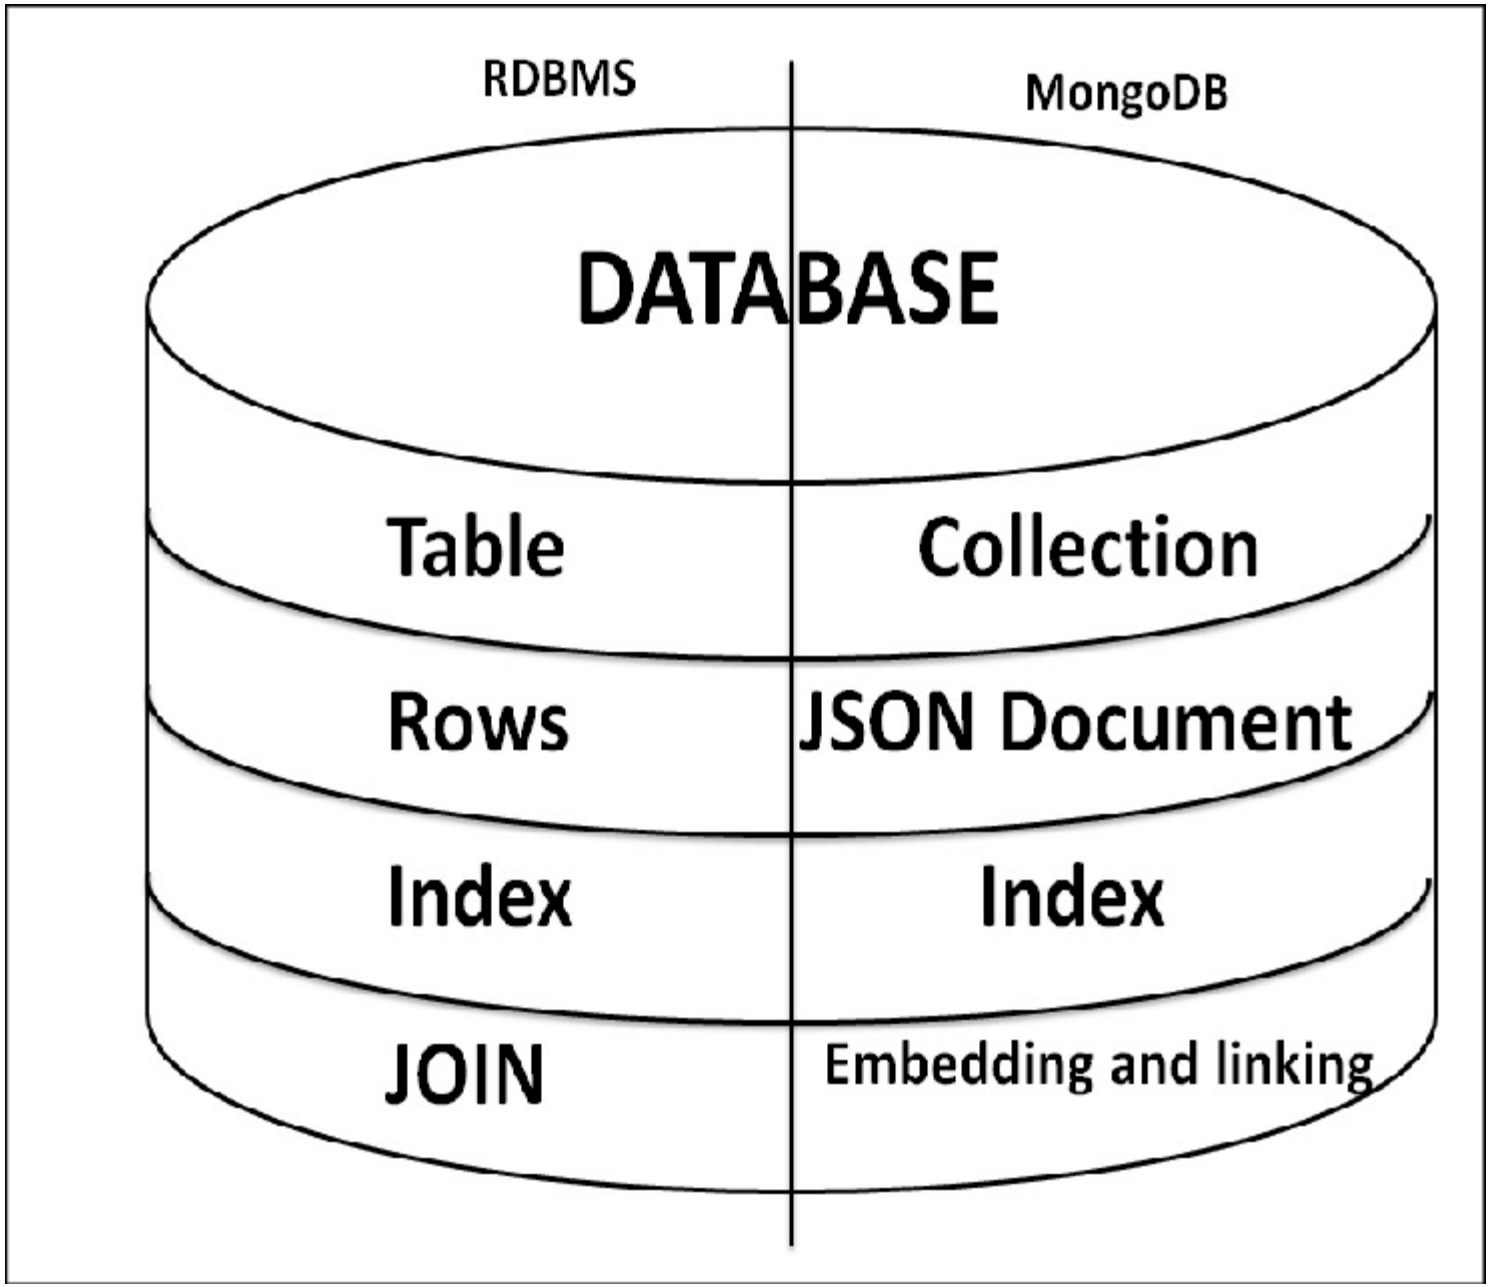
ups i-parcel

intuit.

AstraZeneca

verizon

NBCUniversal


RDBMS
MongoDB
DATABASE
Table
Collection
Rows
JSON Document
Index
Index
JOIN
Embedding and linking

JSON

ویژگی‌های Java Script Object Notation (JSON)

- ساده و خوانا: ساختاری شبیه آبجکت‌های جاوااسکریپت داشته و به‌راحتی قابل فهم و استفاده می‌باشد.
- تقریباً تمام زبان‌های برنامه‌نویسی ابزارهایی برای خواندن و نوشتن JSON دارند.
- مبتنی بر ساختار کلید-مقدار
- ساختار درختی و سلسله‌مراتبی: می‌توان آبجکت درون آبجکت یا آرایه درون آبجکت قرار داد.
- مستقل از پلتفرم و زبان: برای انتقال داده بین سیستم‌های ناهمگون استفاده می‌شود (Web API، موبایل، سرور،...).
- حجم سبک و بهینه: در مقایسه با XML
- پشتیبانی از انواع داده محدود اما کاربردی: آبجکت، آرایه، رشته، عدد، بولین، تهی

مقایسه XML با JSON



- زبان نشانه گذاری شده است. برچسب توصیفی دارد.
- پیچیده تر و سرعت کمتر در اجرا
- همه چیز رشته است

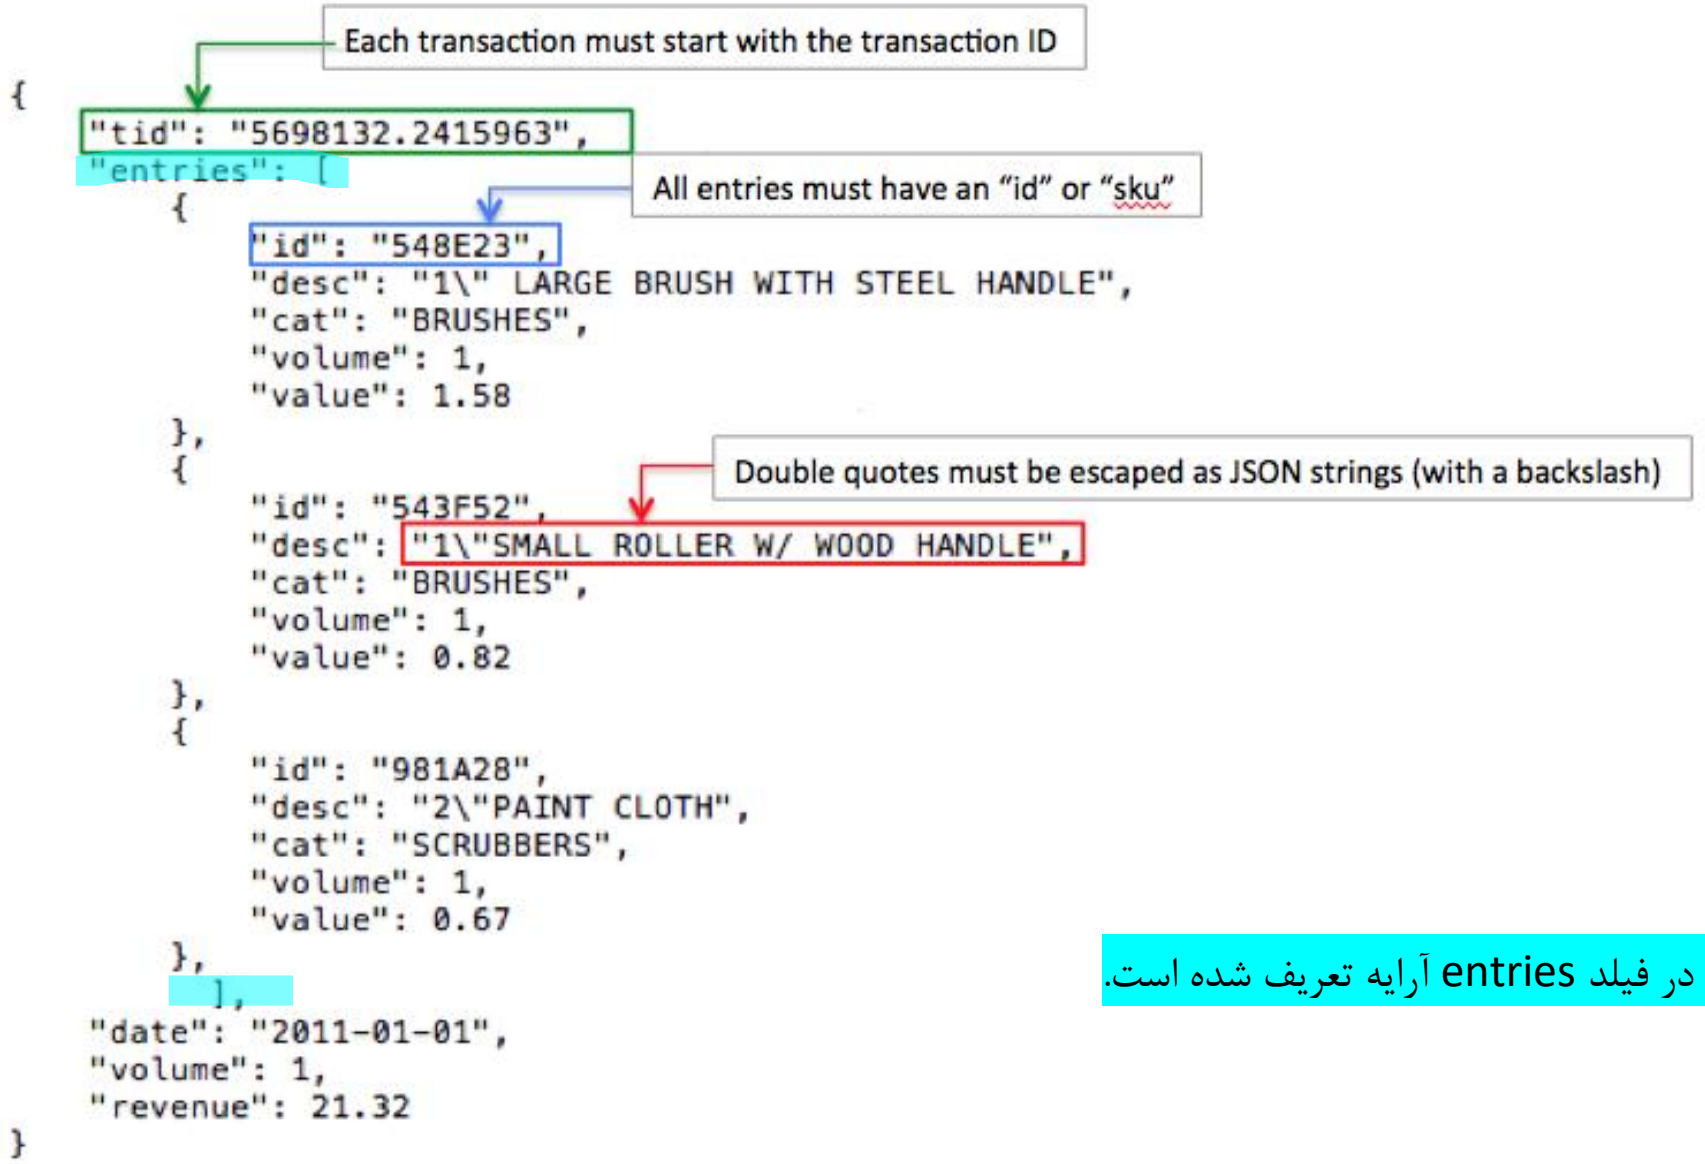
```xml
<user>
  <name>Donie</name>
  <age>25</age>
  <isDeveloper>true</isDeveloper>
</user>
```



- زبان نشانه گذاری شده نیست. برچسب توصیفی ندارد.
- ساده تر و سرعت بیشتر در اجرا
- انواع داده محدود اما کافی

```json
{
  "name": "Donie",
  "age": 25,
  "isDeveloper": true
}
```

فرمت JSON




```
{
    "tid": "5698132.2415963",
    "entries": [
        {
            "id": "548E23",
            "desc": "1\" LARGE BRUSH WITH STEEL HANDLE",
            "cat": "BRUSHES",
            "volume": 1,
            "value": 1.58
        },
        {
            "id": "543F52",
            "desc": "1\"SMALL ROLLER W/ WOOD HANDLE",
            "cat": "BRUSHES",
            "volume": 1,
            "value": 0.82
        },
        {
            "id": "981A28",
            "desc": "2\"PAINT CLOTH",
            "cat": "SCRUBBERS",
            "volume": 1,
            "value": 0.67
        },
        ],
    "date": "2011-01-01",
    "volume": 1,
    "revenue": 21.32
}
```

با توجه به براکت‌ها [] متوجه میشویم که در فیلد entries آرایه تعریف شده است.